

Программа курса

**Big Data Analytics:
Approaches and Tools**

- Hadoop: Hadoop Distributed File System (HDFS)
- Управление ресурсами и приложениями (YARN), платформа MapReduce
- Apache Spark. Распределенная координация с Zookeeper
- Системы потоковой обработки. Apache Storm. Spark Streaming.
- Системы потоковой обработки. Apache Flink. Kafka
- Системы обработки графов: Giraph, Spark GraphX, Spark GraphFrames
- Kubernetes. Управление контейнеризированными приложениями

- HDFS и MapReduce
- Spark. Основные операции над RDD
- Spark. Основные операции над Dataframe
- Spark. Взаимодействие с HDFS, Parquet, Avro
- Поточковая обработка. Разработка Storm приложений
- Поточковая обработка. Разработка приложений под Spark Streaming
- Обработка графов. Разработка приложений под Spark GraphX и GraphFrame
- Развертывание Spark на Kubernetes

- MapReduce
- Spark + Kafka
- Spark + MLlib
- Spark GraphFrame

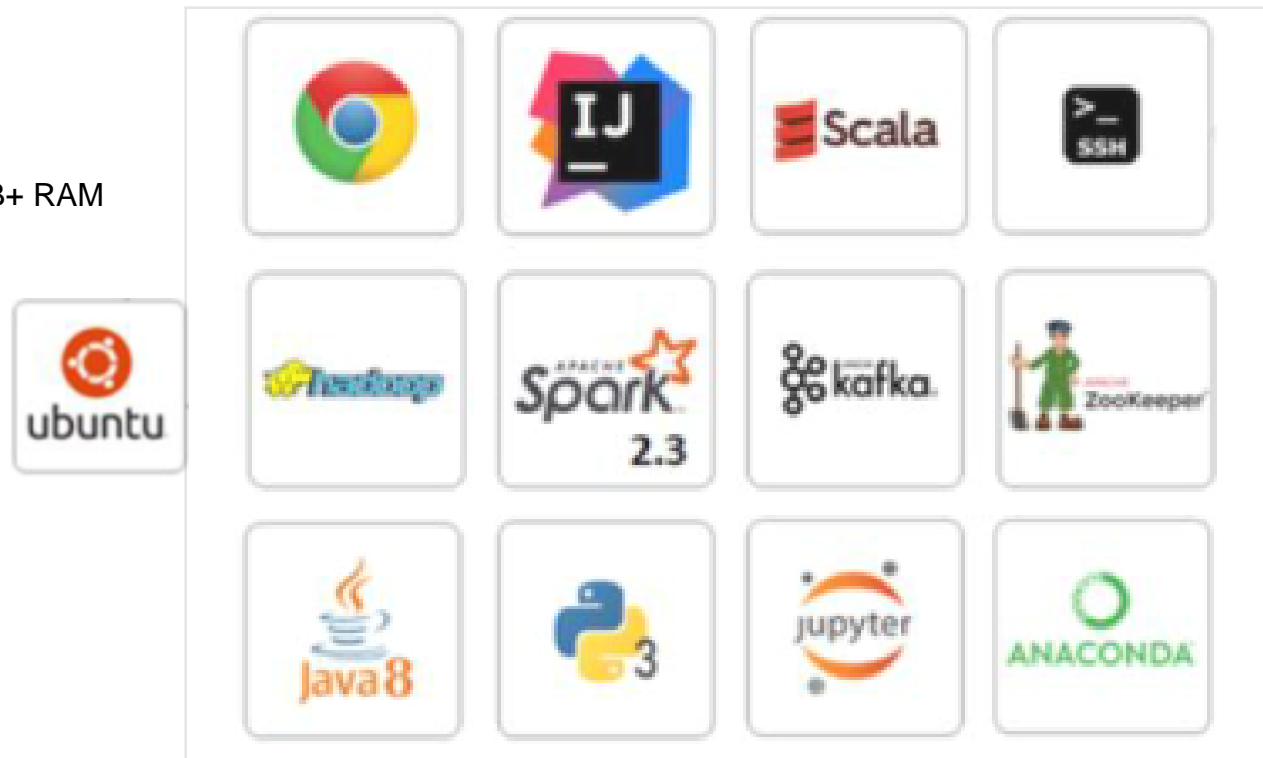
cloudera



Java, Scala, Python

https://github.com/BosenkoTM/BigDataAnalytic_Practice

РАБОЧАЯ МАШИНА СТУДЕНТА 8GB+ RAM



Big Data Analytics: Approaches and Tools

Основные темы

- Большие данные – 4V
- Параллельные и распределенные вычисления
- Системы обработки и хранения больших данных
- Стек технологий
- Облачные ресурсы



Системы обработки больших данных

Пример, Facebook

- 2.79 млрд. активных пользователей в месяц (2021)

4 млн. лайков каждую минуту





Большие Данные – 4V



- Чем больше данных у нас есть, тем больше знаний мы можем извлечь, лучшее решение можем принять
- Чем быстрее обрабатываются поступающие данные, тем быстрее можно начать анализ
- Чем более разнообразные источники данных (социальные сети, история просмотров, покупок и пр.), тем лучше можно составить портрет клиента
- Чем более достоверные данные, тем точнее можно составить портрет клиента

Источники данных

Публичные данные

Экономические
Перепись
Гео-информация
Погода
Открытые данные

Коммерческие данные

Бизнес-информация
Исследования рынка
Кредитное бюро

Социальные сети

Сообщества
Блоги
Twitter, Facebook, LinkedIn, Tumblr

Операционные данные

Сенсоры
GPS
Транзакции

Корпоративные данные

Взаимодействия с клиентами
Отчеты
Логи
Контакты


Основные задачи систем обработки больших данных

- ETL (Extract, Transform, Load)
- Поиск информации
- Анализ данных
- Машинное обучение

Extract Transform Load

ETL. Общая схема

- Извлечение данных из различных внешних источников (БД, приложения, системы)
- Преобразование и очистка данных в соответствии с целями обработки
- Загрузка результата в хранилище данных



ETL. Базовые трансформации

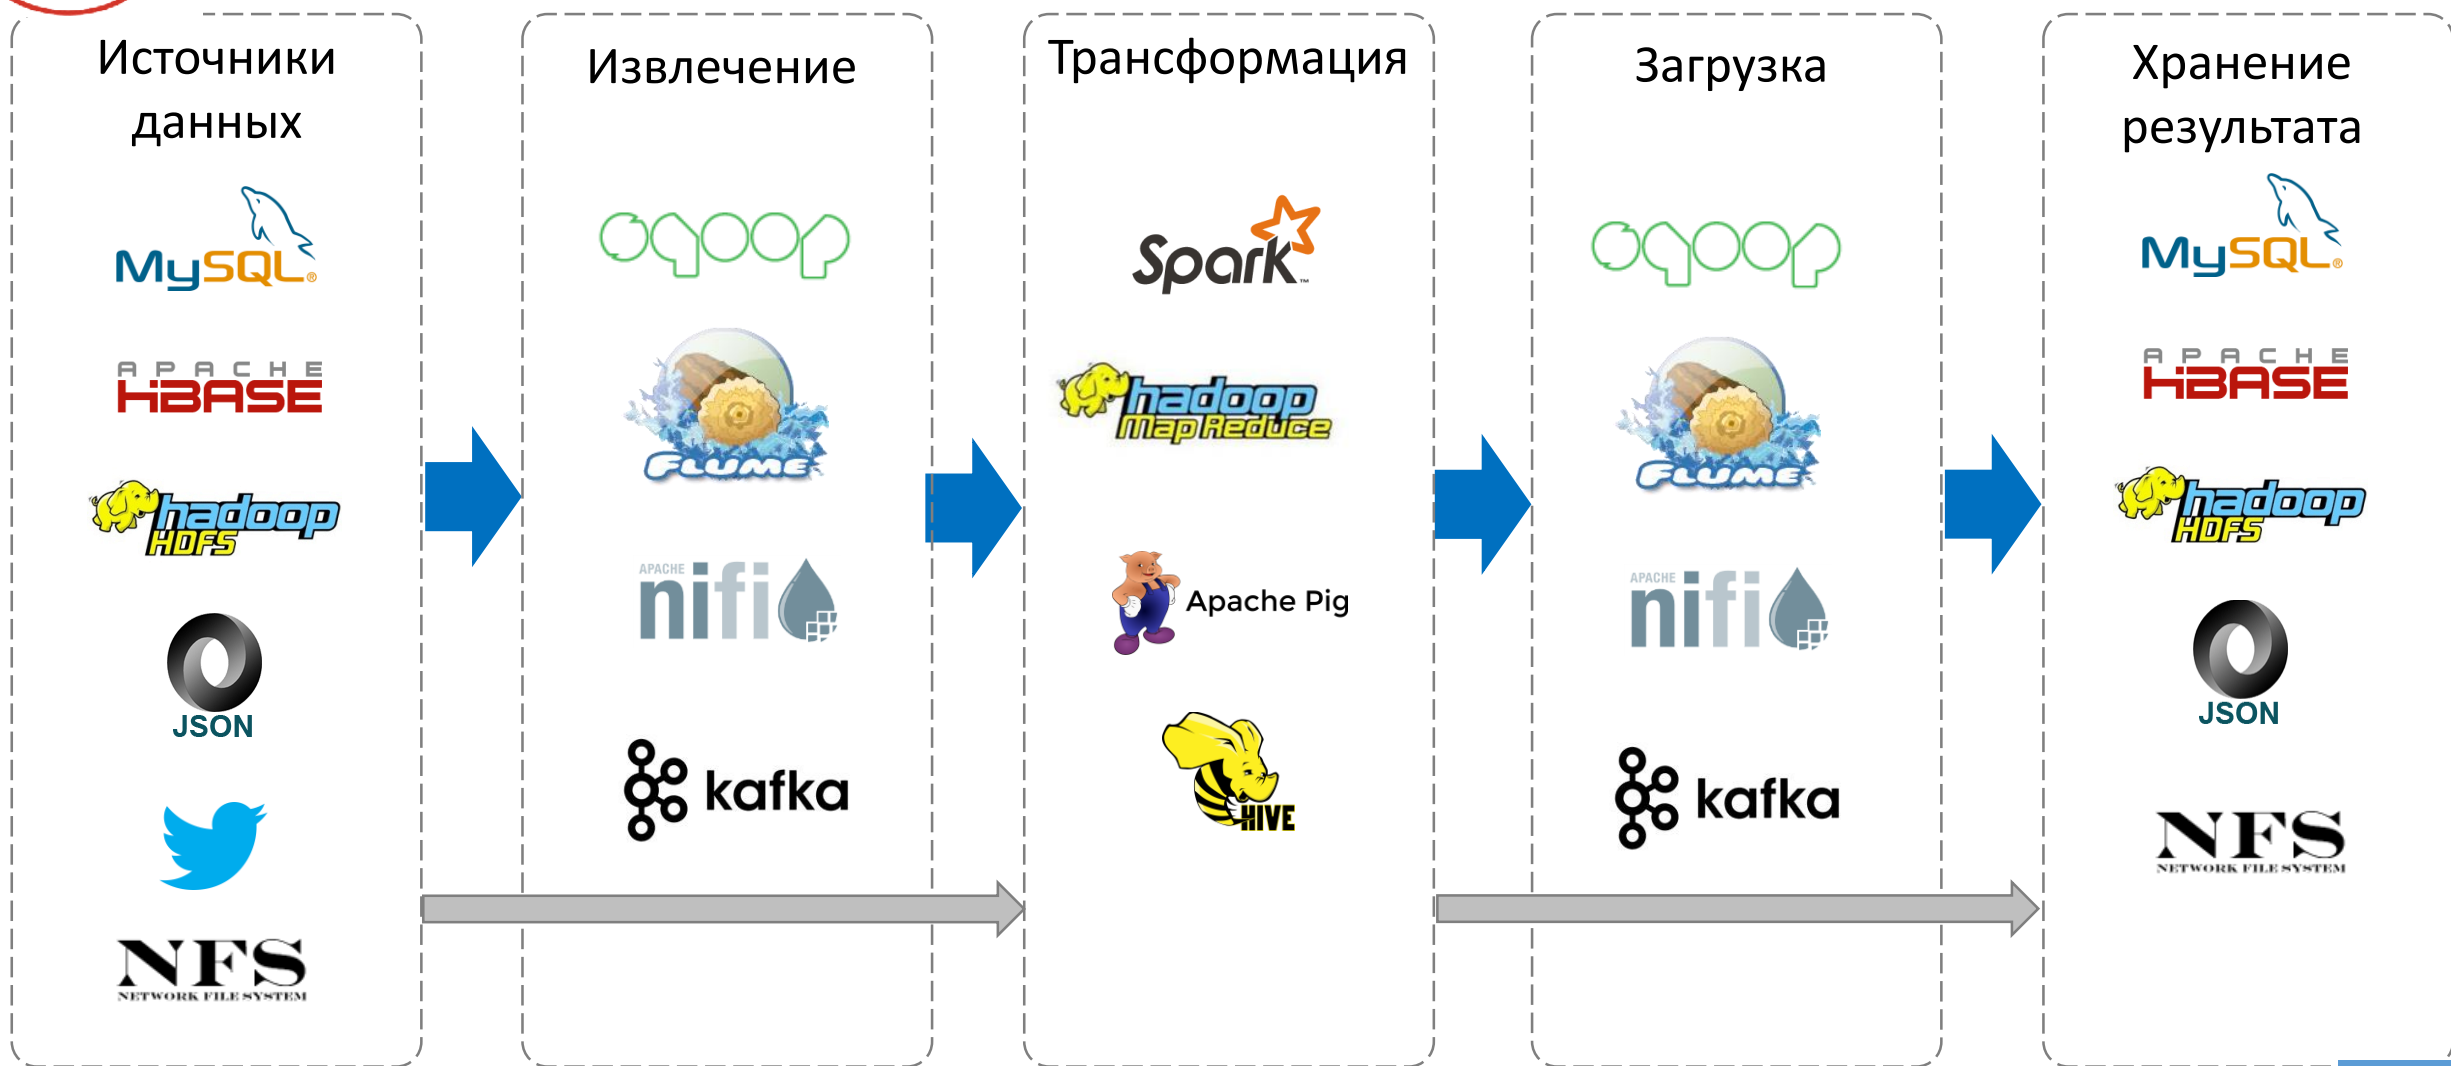
- **Очистка (cleaning)**
обработка null значений, пропущенных данных, аномальных значений и пр.)
- **Преобразование формата (format revision)**
преобразование формата даты, времени, единиц измерения и пр.)
- **Преобразование структуры данных (restructuring)**
- **Дедубликация (deduplication)**
удаление повторных записей

ETL. Трансформации

- **Фильтрация** (filtering)
- **Получение производных данных** (derivation)
- **Агрегирование** (aggregation)
- **Обобщение/резюме** (summarization)
сводные данные на разных уровнях, например, страна, регион, город и пр.
- **Слияние** (merging)
- **Разделение** (splitting)
(например, одного столбца на несколько)

и др.

ETL. Общая схема



Поиск информации



Индексирование текстовых документов

- Формирование вектора термов документа (предобработка, токенизация, семминг и пр.)
- Формирование инвертированного индекса



Поиск по текстовому запросу

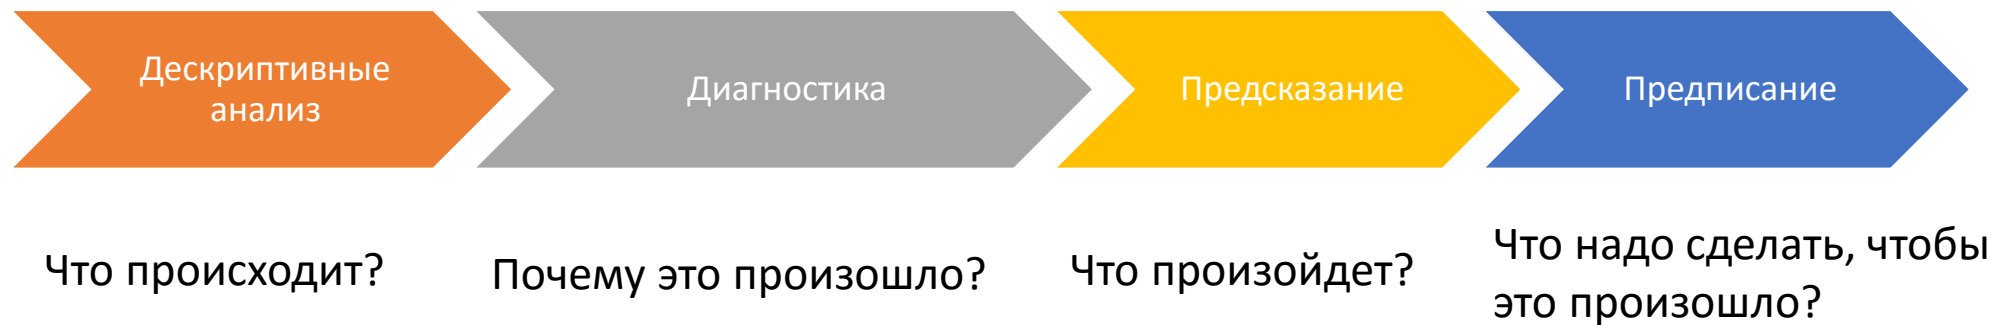
- Формирование вектора термов запроса (предобработка, токенизация, семминг и пр.)
- Отбор документов по инвертированному индексу
- Ранжирование отобранных документов по релевантности



Оптимизация



Анализ данных и машинное обучение



Дескриптивный анализ

Предобработка данных (очистка, отбор признаков, преобразование признаков)

Обучение с учителем (регрессия, классификация)

Обучение без учителя (кластеризация, уменьшение размерности, выявление аномалий, тематическое моделирование)

Рекомендательные системы (рекомендации товаров на основе поведения и предпочтений)


Анализ графов (выявление взаимосвязей различных структур в графе)

Глубокое обучение

Решаемые задачи




Анализ данных и машинное обучение



Spark: The Definitive Guide By Bill Chambers & Matei Zaharia (book)

Наука о данных (Data Science)




Архитектура систем обработки больших данных


Вычислительные ресурсы

Общие данным

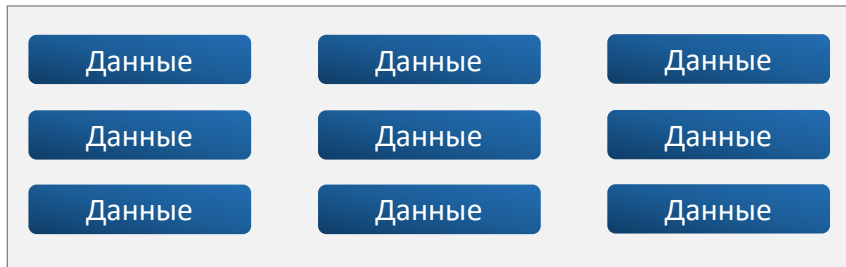
Приложения




СУБД




SAN/NAS



Данные обрабатываются там же, где они хранятся



Наращивание производительности



Кластер

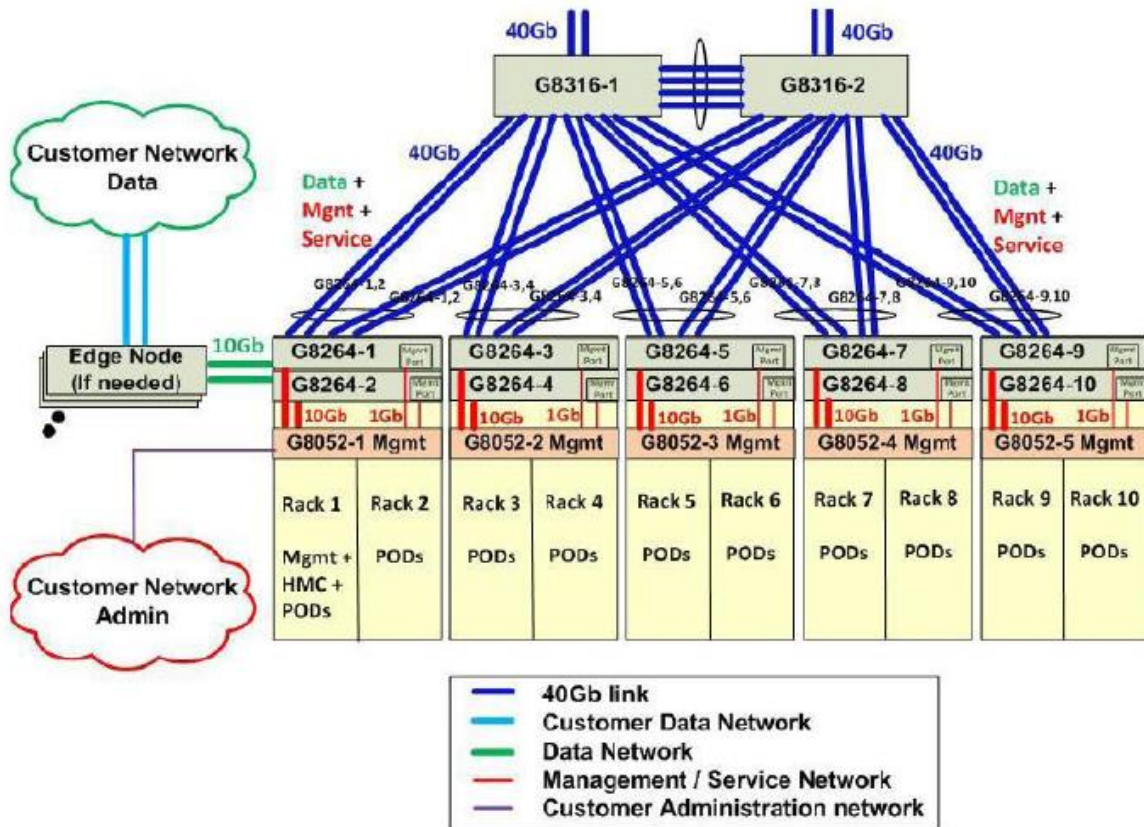
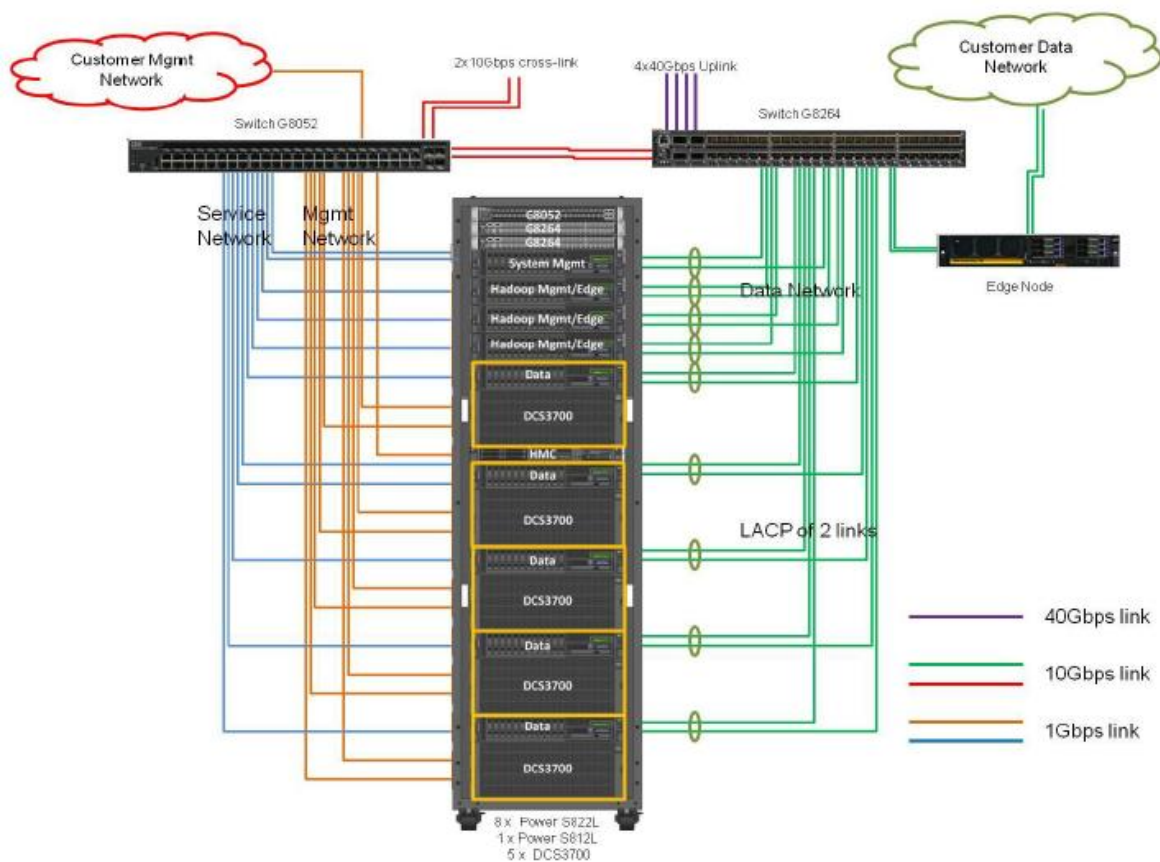




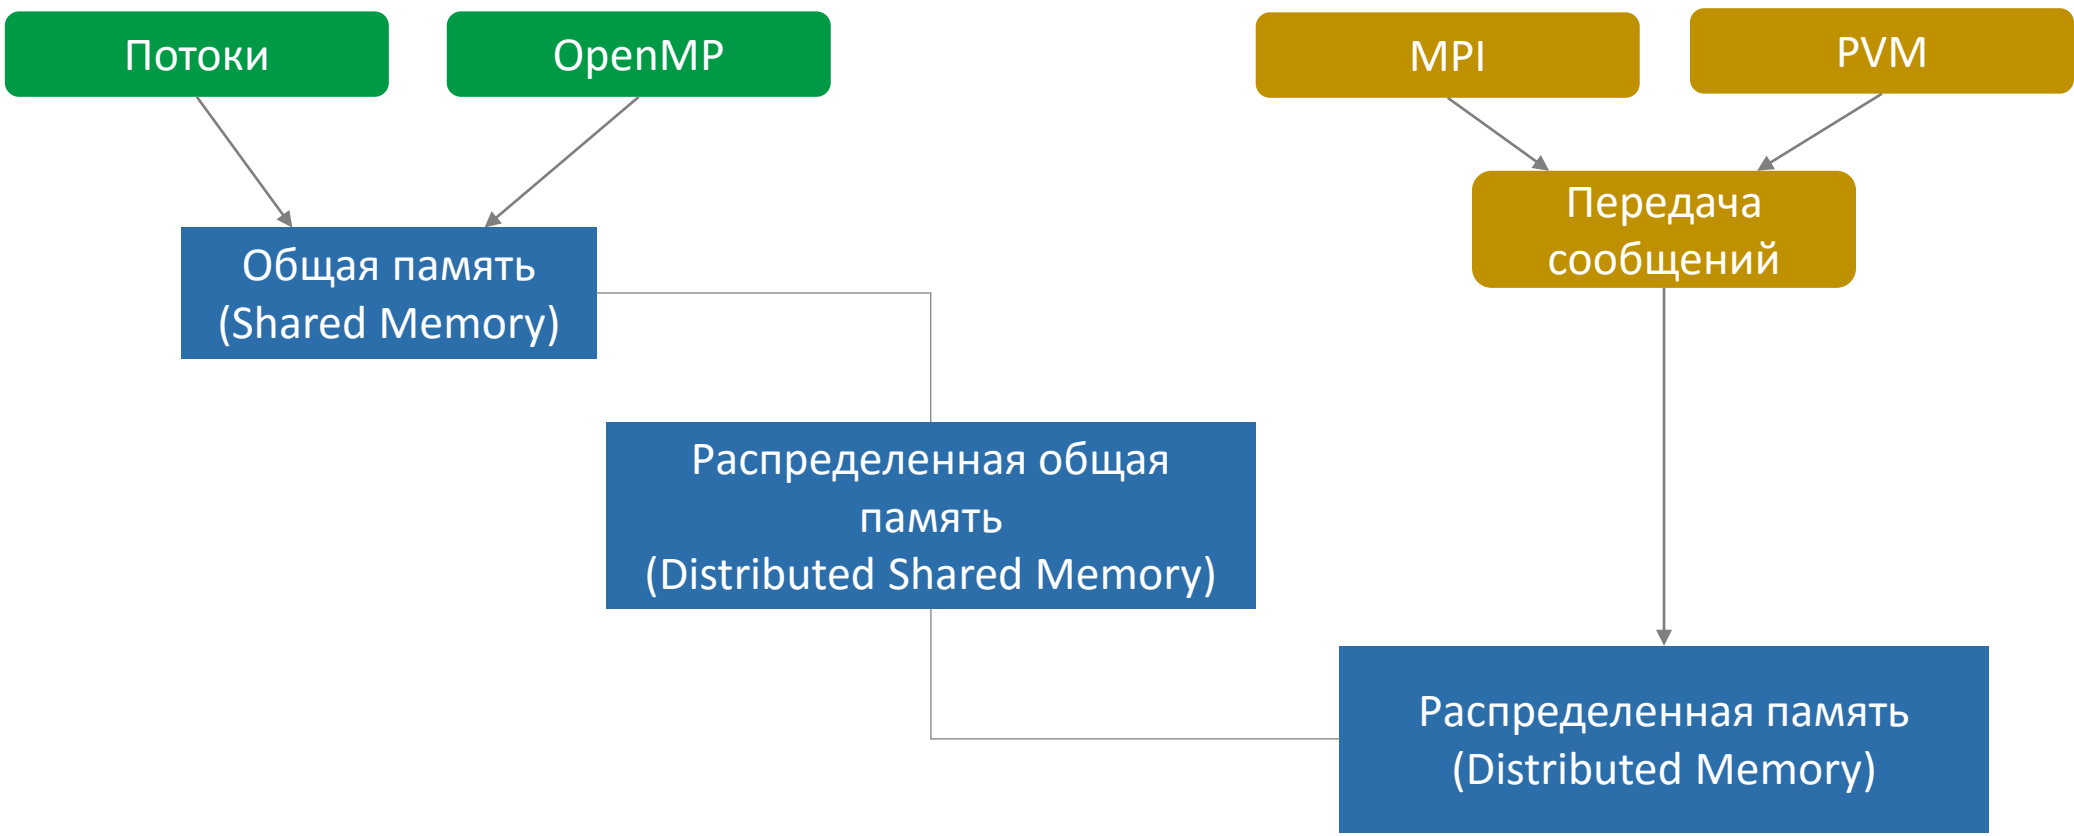
Figure 6: Cross-rack networking





Параллельные и распределенные вычисления


Параллельное программирование



Распределенные приложения

Что необходимо учитывать

- Сеть не обязательно надежна
- Существуют задержки
- Пропускная способность ограничена
- Сеть может быть небезопасной
- Топология может изменяться
- Может быть несколько администраторов
- Существуют транспортные затраты
- Сеть может быть гетерогенной





Синхронная

HTTP REST THRIFT



Асинхронная

WebSocket



Координация



Выбор мастера (Master election)

Назначение задач worker'ам



Обнаружение отказа (Crash detection)

Мастер должен уметь определять, что worker вышел из строя или с ним потеряно соединение



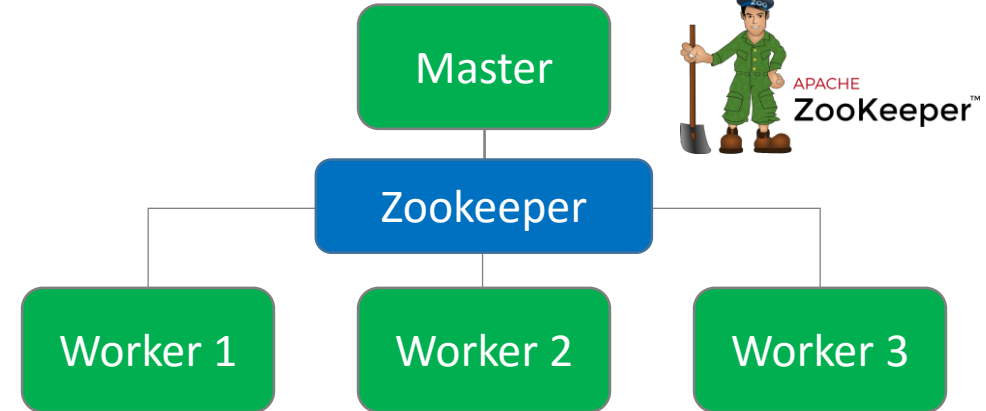
Управление группами (Group membership management)

Мастер должен знать, какие worker'ы доступны для выполнения задач



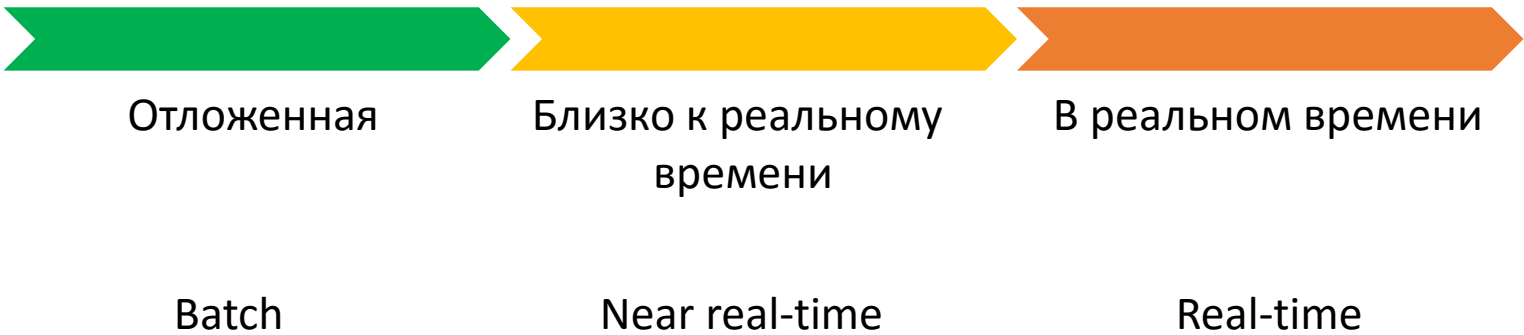
Управление метаданными (Metadata management)

Мастер и worker'ы должны хранить задания и статусы выполнения надёжным способом



Системы обработки и хранения больших данных

Вычисления



Классификация систем

Принципы выполнения вычислений



Обработка коллекций данных (batch processing)




Обработка потоковых данных (stream processing)

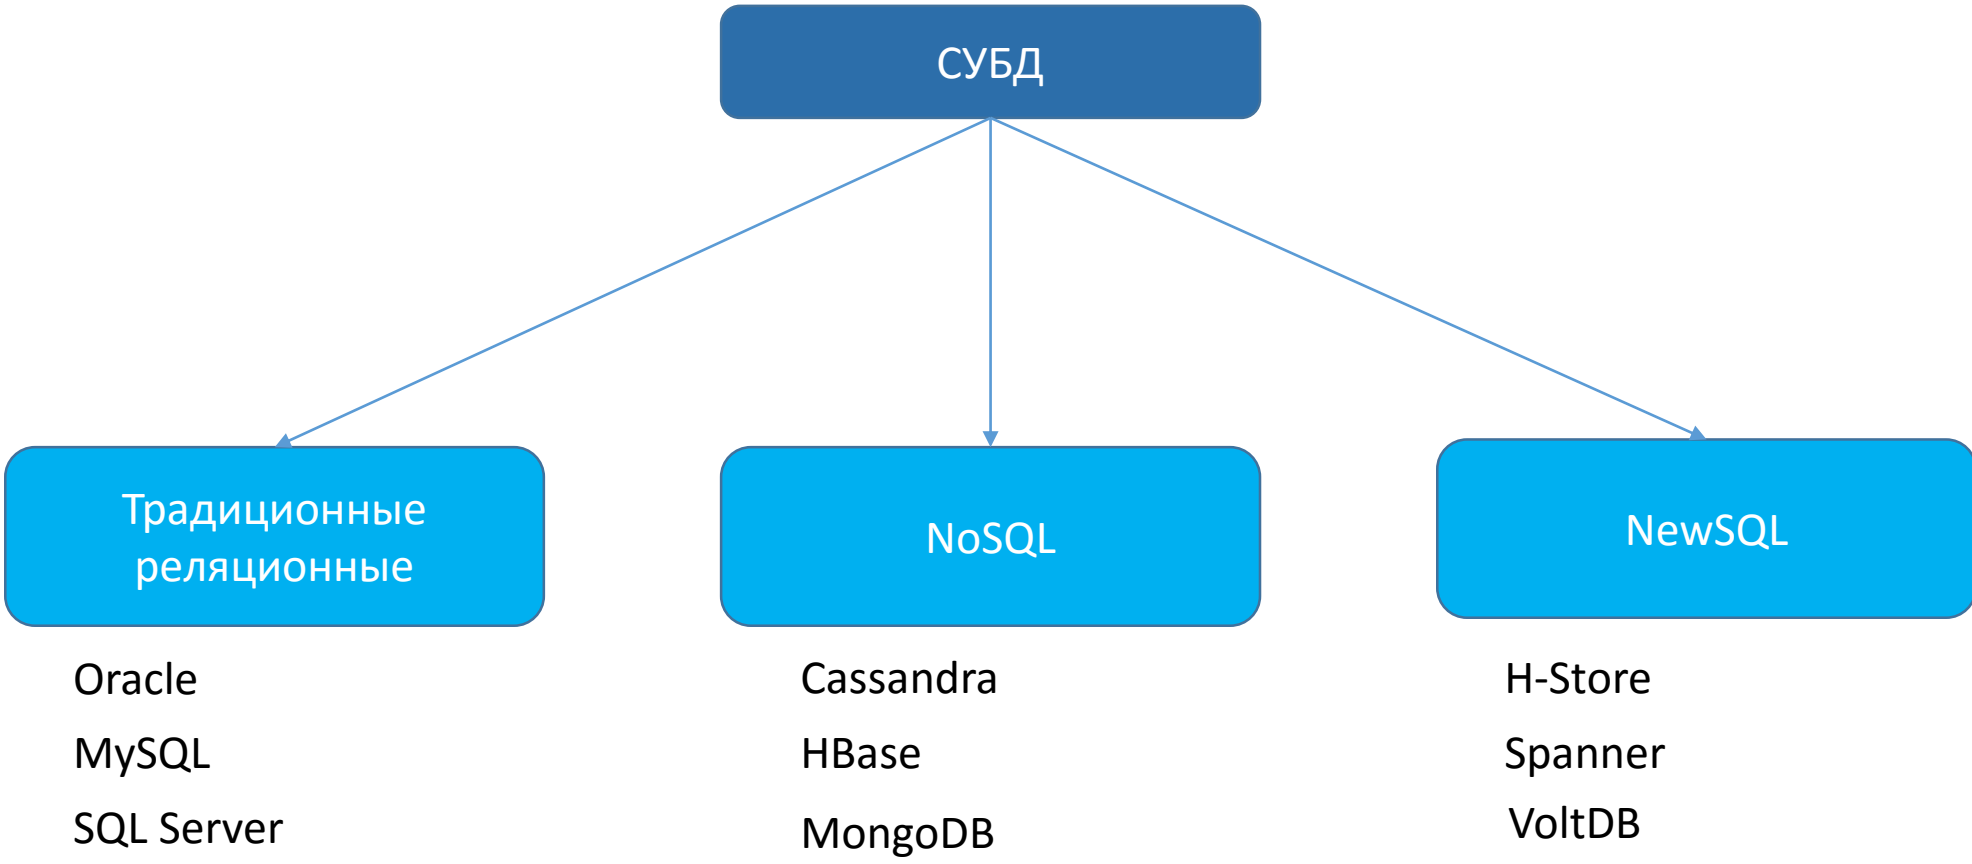


Обработка графов (graph processing)

ИНСТИТУТ
ЦИФРОВОГО
ОБРАЗОВАНИЯ
МГПУ



Классификация NoSQL СУБД





ACID vs BASE

ACID

Атомарность (Atomicity)

Согласованность (Consistency)

Изолированность (Isolation)

Долговечность (Durability)

BASE

Basic Availability

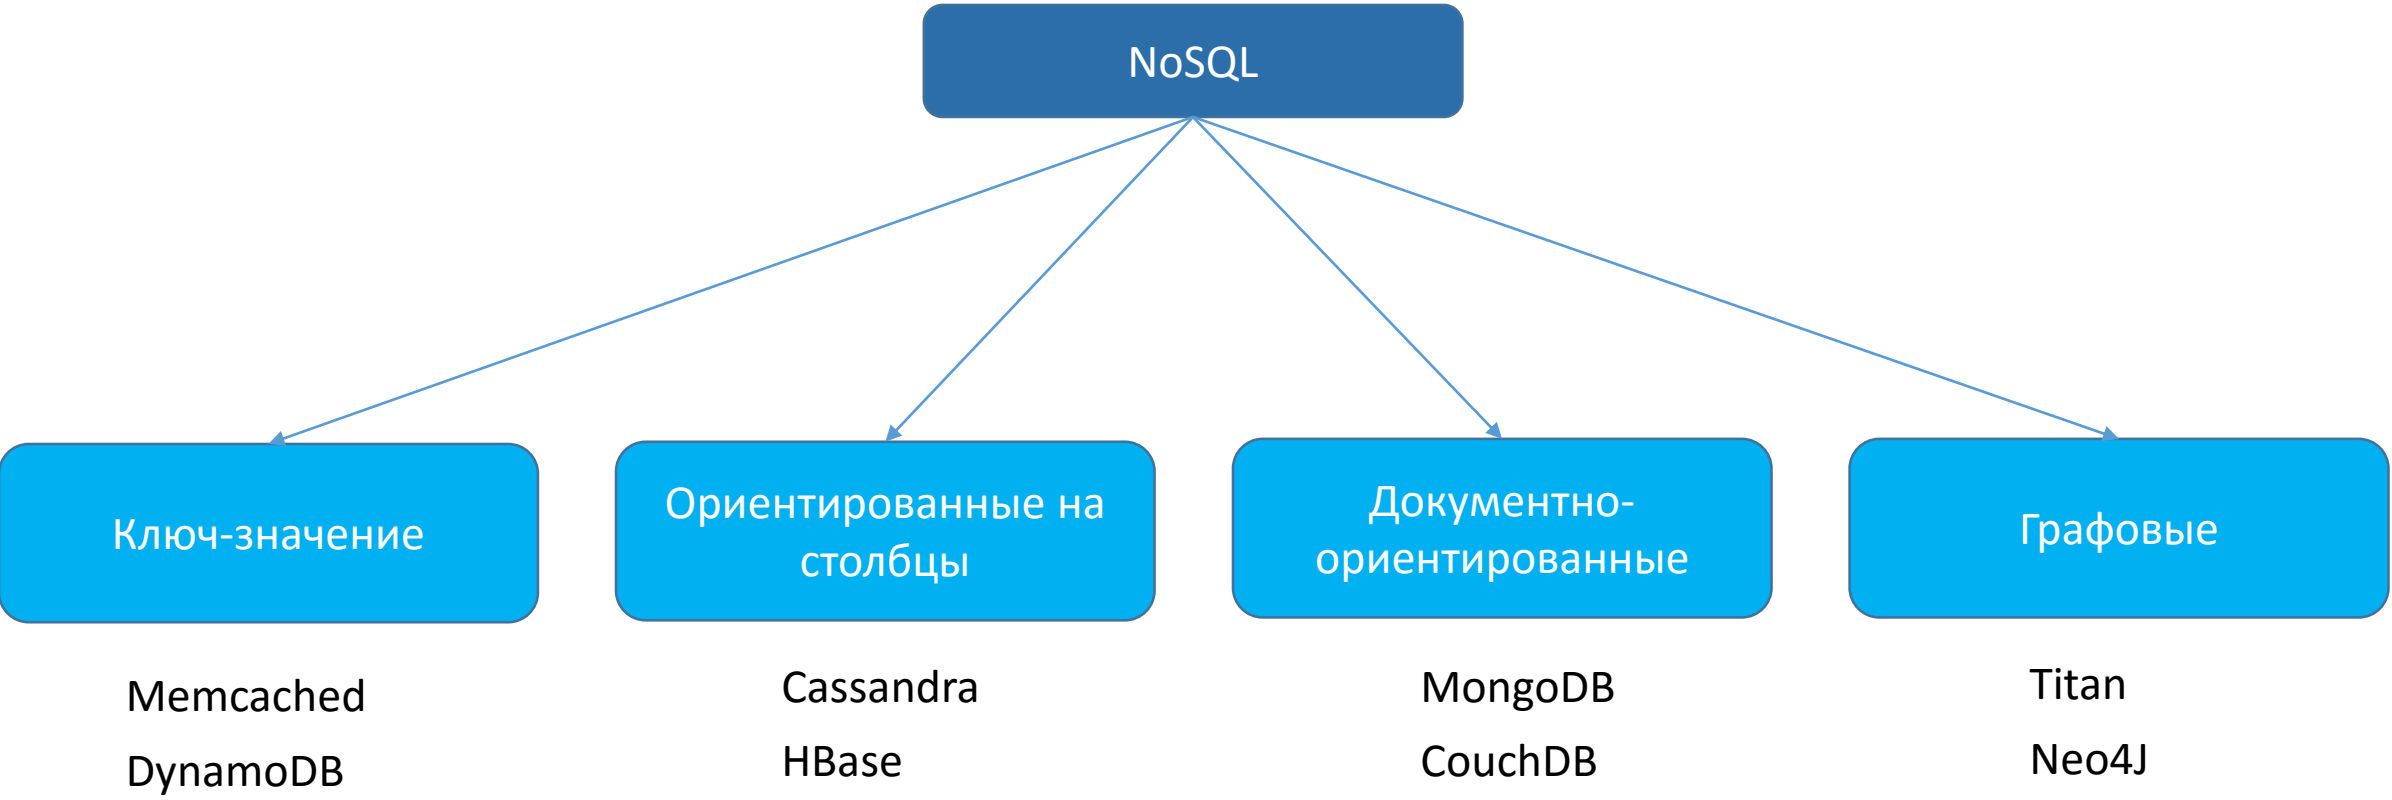
Soft-state

Eventual consistency

CAP



Классификация NoSQL СУБД



Примеры СУБД

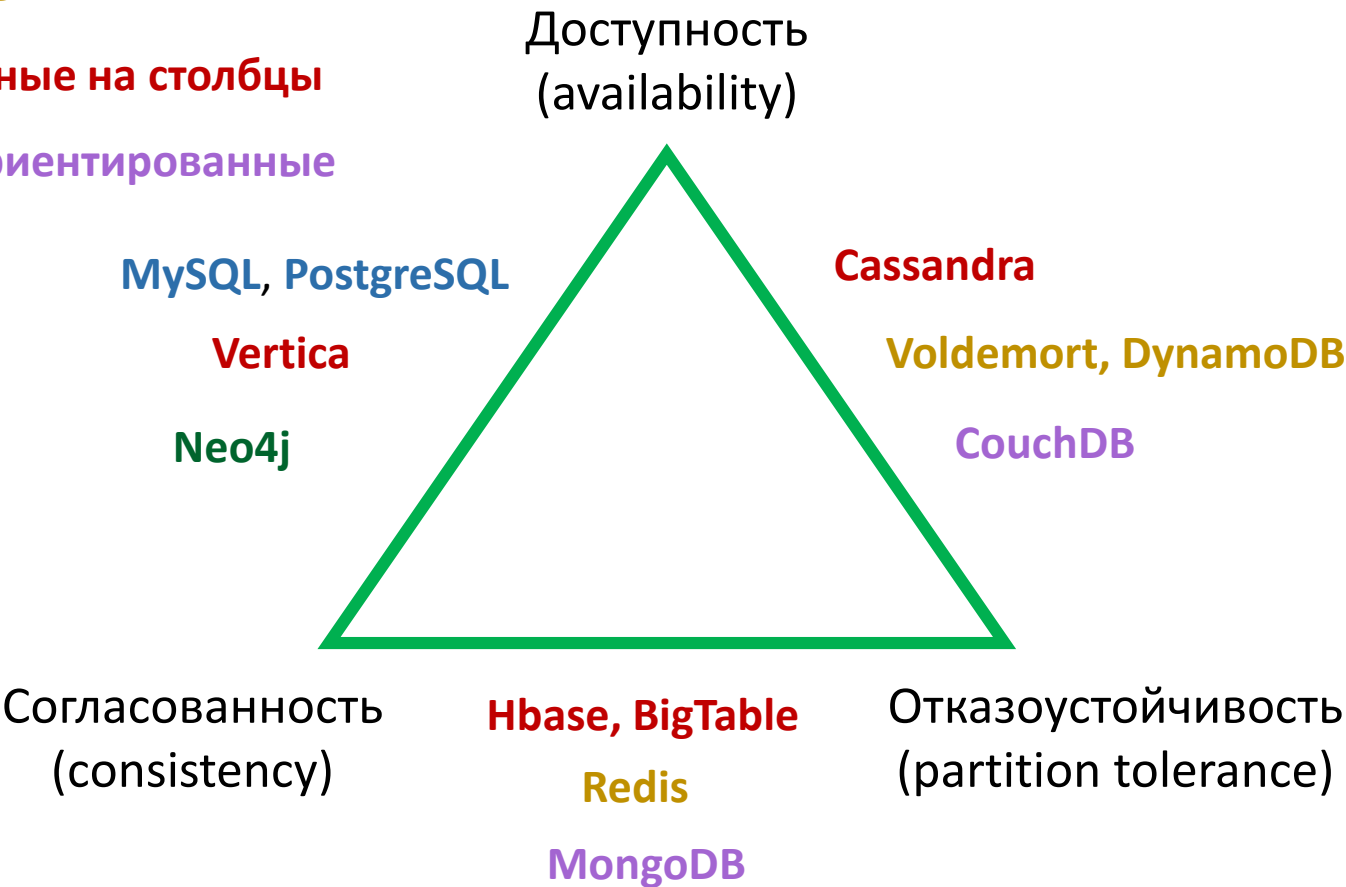
Реляционные

Ключ-значение


Ориентированные на столбцы

Документно-ориентированные

Графовые



Примеры СУБД



Customer Table

CustomerID	Title	FirstName	LastName	AddressID
1	Mr	Mark	Hanson	500
2	Ms	Lisa	Andrews	501
3	Mr	Walter	Harp	500

Address Table

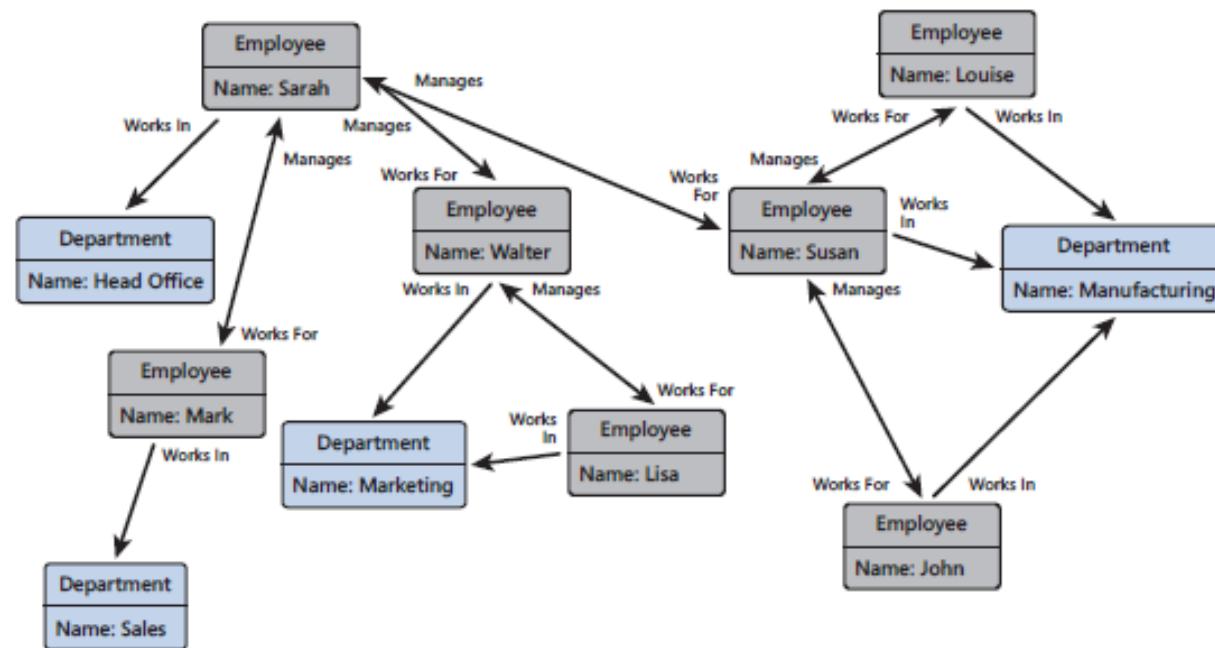
AddressID	StreetAddress	City	State	ZipCode
500	999 500th Ave	Bellevue	WA	12345
501	888 W. Front St	Boise	ID	54321

Key	Value (blob)
AAAAA	110100100100111101001001001
AABAB	000110100111100100011110010
DFA766	01011001100100110011111001011
FABCC4	1111000011001010010110011001

Row Key	Column Families			
CustomerID	CustomerInfo		AddressInfo	
1	CustomerInfo:Title	Mr	AddressInfo:StreetAddress	999 Thames St
	CustomerInfo:FirstName	Mark	AddressInfo:City	Reading
	CustomerInfo:LastName	Hanson	AddressInfo:County	Berkshire
			AddressInfo:PostCode	RG99 922
2	CustomerInfo:Title	Ms	AddressInfo:StreetAddress	888 W. Front St
	CustomerInfo:FirstName	Lisa	AddressInfo:City	Boise
	CustomerInfo:LastName	Andrews	AddressInfo:State	ID
			AddressInfo:ZipCode	54321
3	CustomerInfo:Title	Mr	AddressInfo:StreetAddress	999 500th Ave
	CustomerInfo:FirstName	Walter	AddressInfo:City	Bellevue
	CustomerInfo:LastName	Harp	AddressInfo:State	WA
			AddressInfo:ZipCode	12345

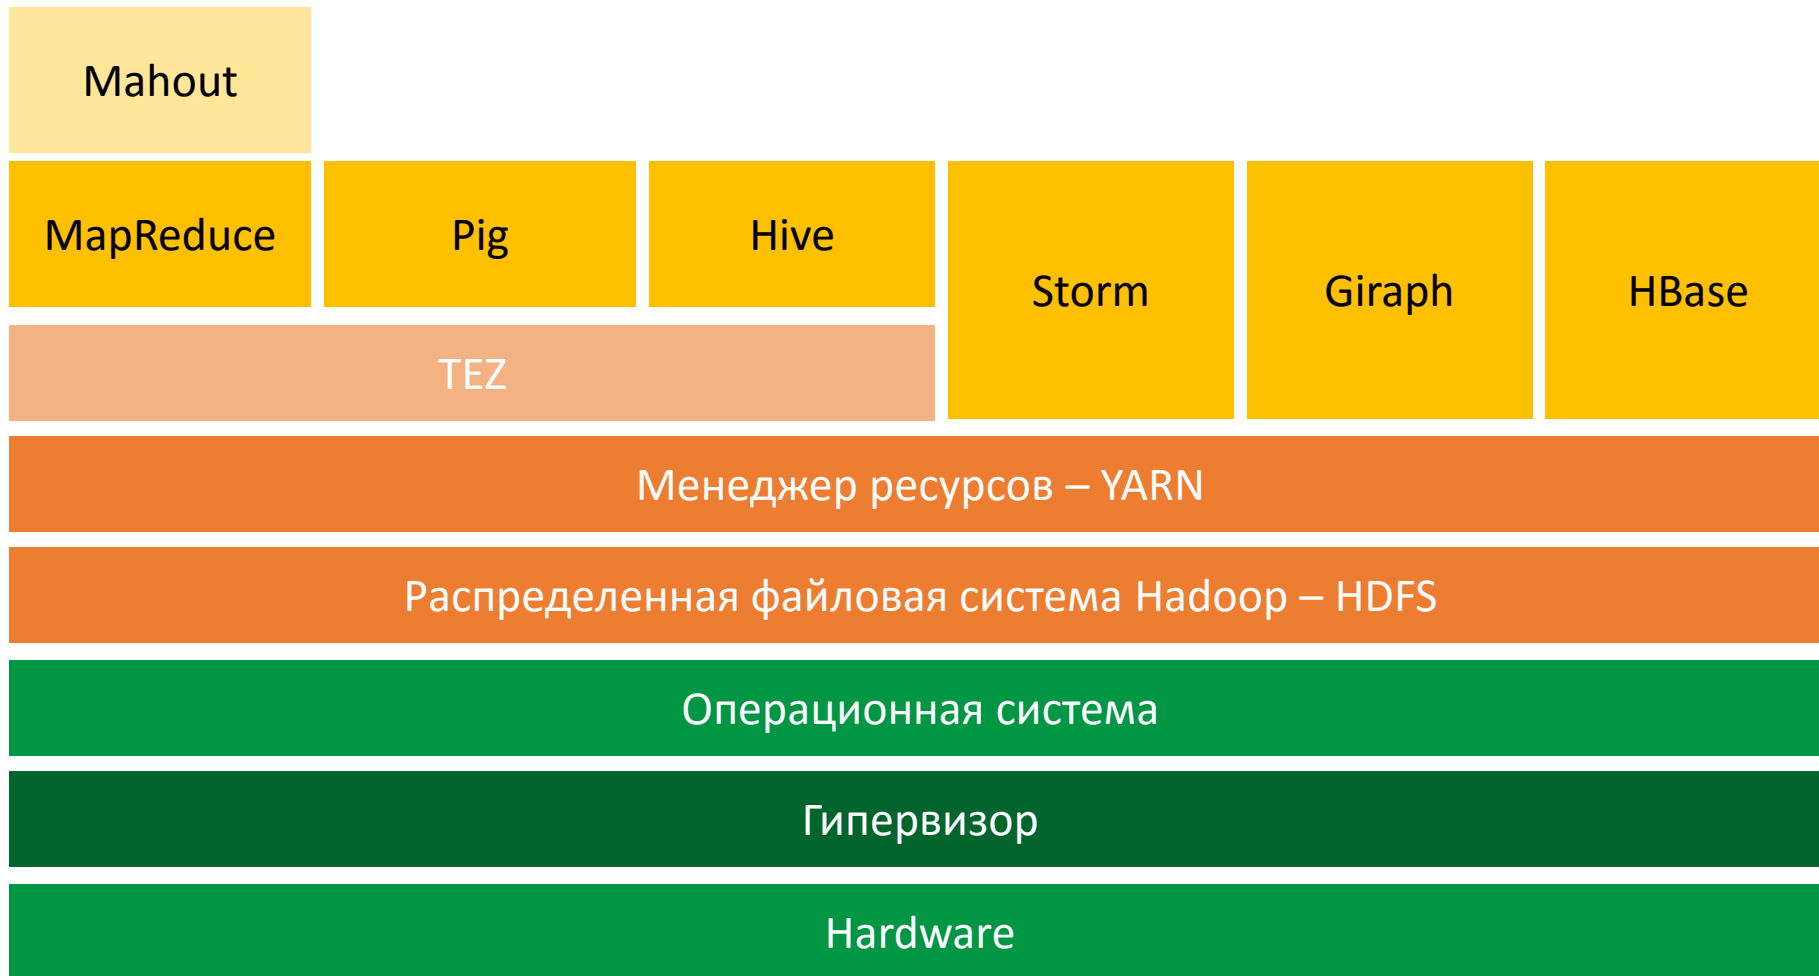
Примеры СУБД

Row Key	Document
1001	<p>OrderDate: 06/06/2013 OrderItems: ProductID: 2010 Quantity: 2 Cost: 520</p> <p>ProductID: 4365 Quantity: 1 Cost: 18</p> <p>OrderTotal: 1058 Customer ID: 99 ShippingAddress: StreetAddress: 999 500th Ave City: Bellevue State: WA ZipCode: 12345</p>
1002	<p>OrderDate: 07/07/2013 OrderItems: ProductID: 1285 Quantity: 1 Cost: 120</p> <p>OrderTotal: 120 Customer ID: 220 ShippingAddress: StreetAddress: 888 W. Front St City: Boise State: ID ZipCode: 54321</p>



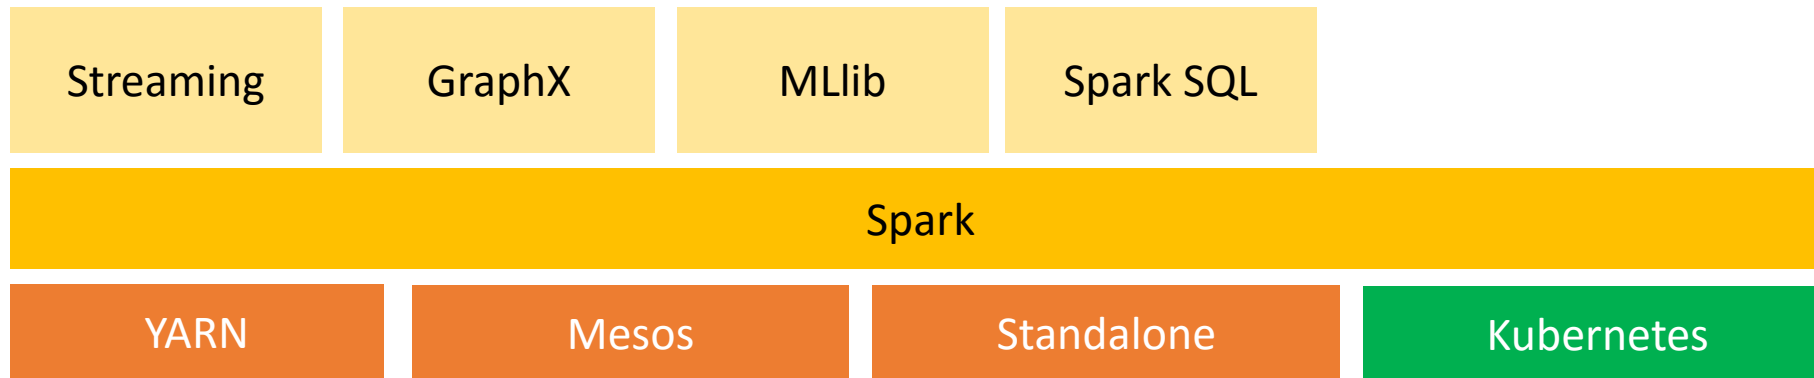
Стек технологий Hadoop и Spark

Стек Hadoop






Стек Spark

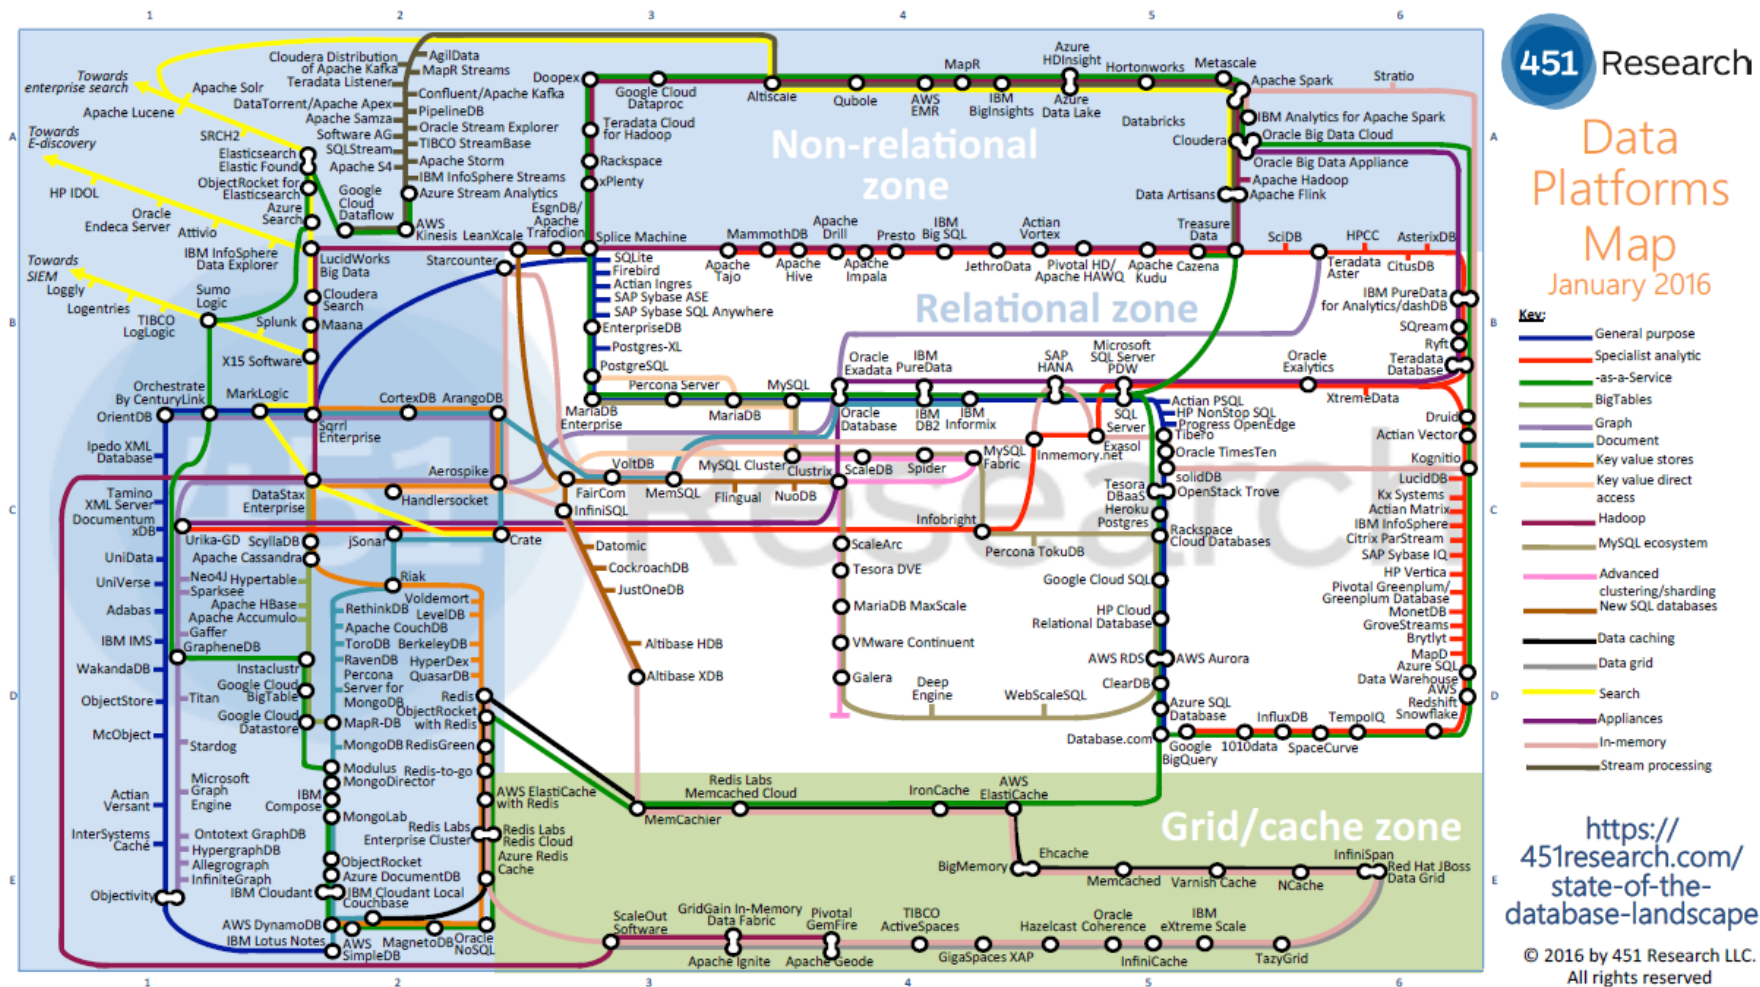


Стек технологий



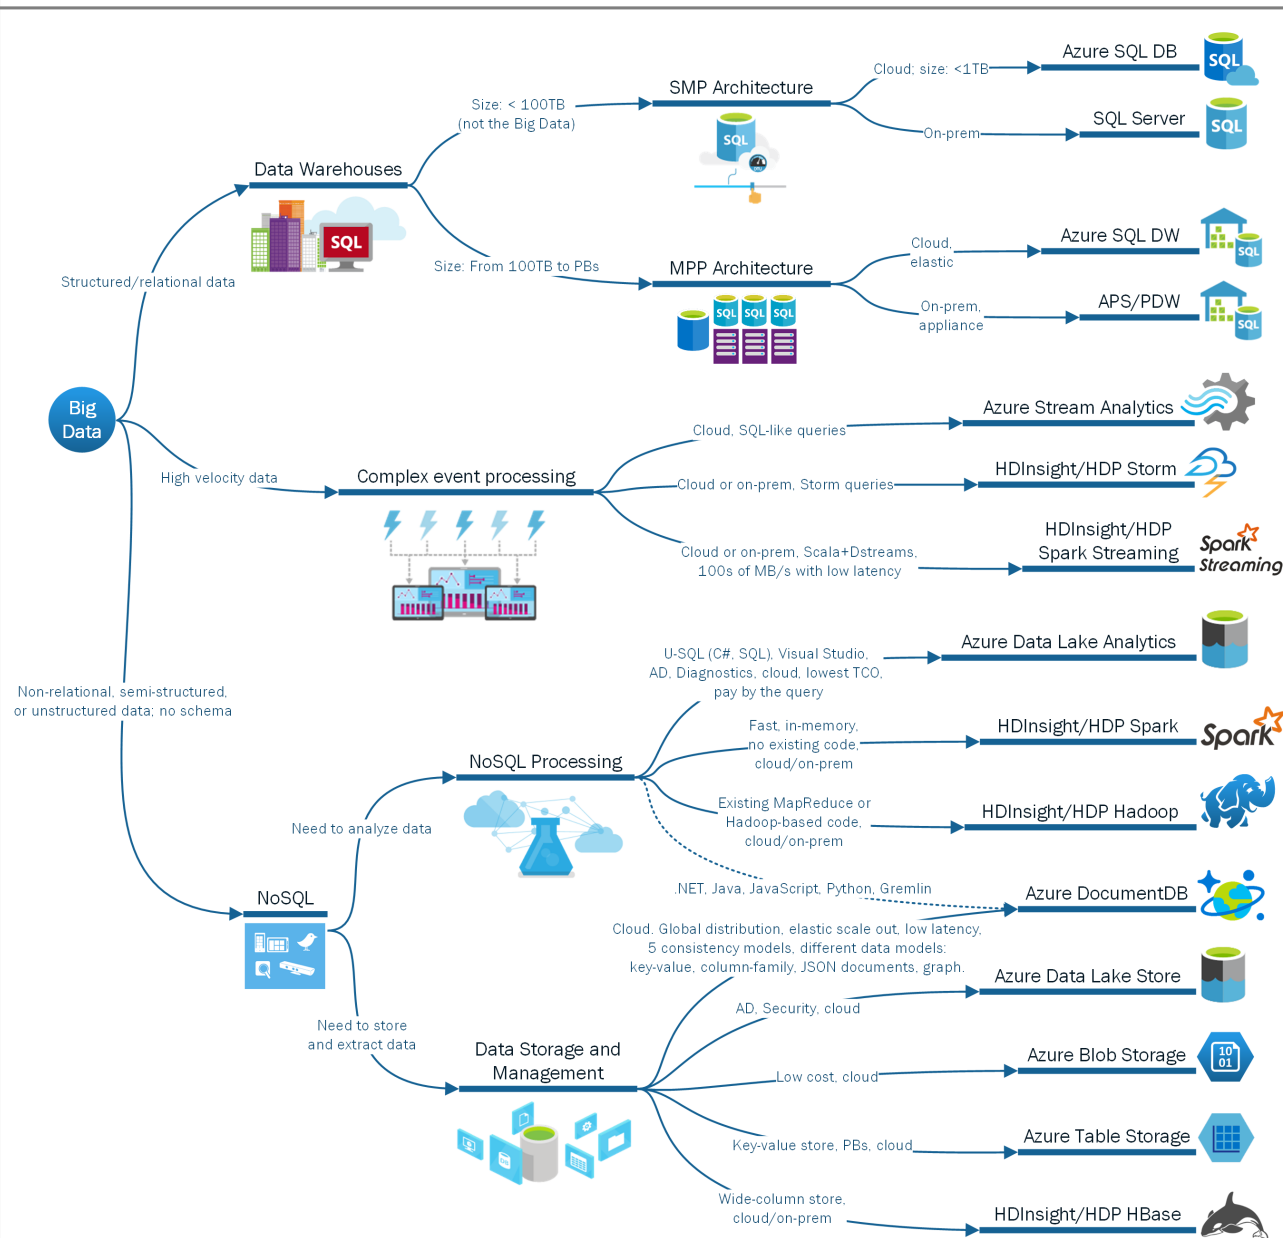
MapR

Карта технологий



Big Data Solutions Decision Tree

Version 2.01. May 30, 2016. Author: Ivan Kosyakov, Ph.D., Technical Architect in Microsoft Technology Center New York

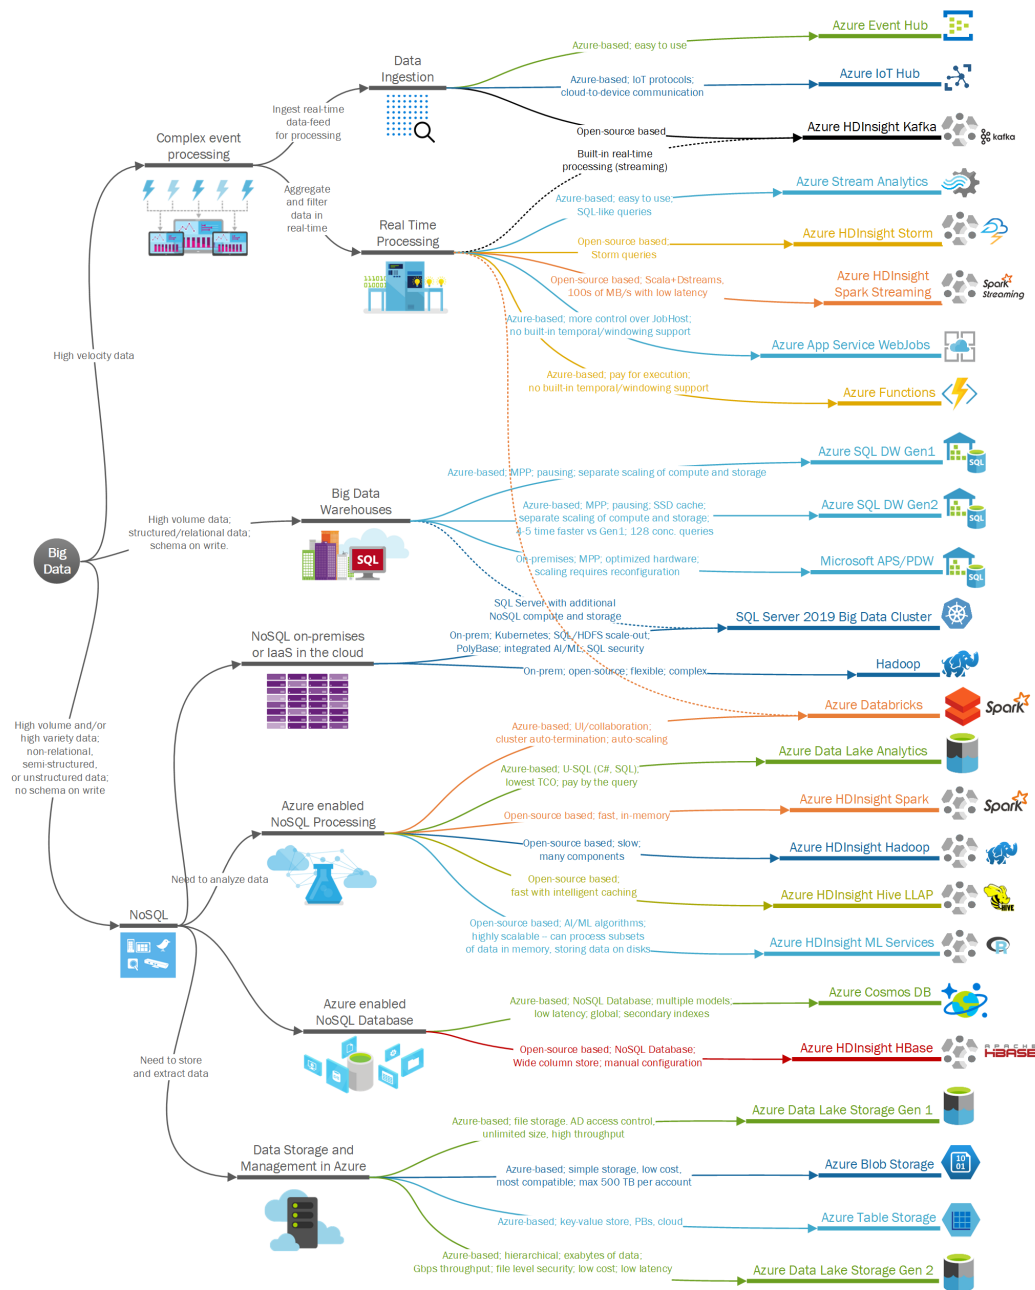




ИНСТИТУТ
ЦИФРОВОГО
ОБРАЗОВАНИЯ
МГПУ

Big Data Solutions Decision Tree

Version 4.02. January 15, 2019. Author: Ivan Kosyakov, Ph.D., Technical Architect in Microsoft Technology Center New York



Облачные ресурсы

Облачные ресурсы



Облачные ресурсы



Облачные ресурсы



Инфраструктуры анализа больших данных




Hadoop и Spark
Amazon EMR



Elasticsearch
Сервис Amazon Elasticsearch

Анализ больших данных в режиме реального времени



Amazon Kinesis Firehose



Amazon Kinesis Streams



Amazon Kinesis Analytics

Хранилища и базы больших данных



Объектное хранилище
Amazon S3



NoSQL
Amazon DynamoDB



HBase в Amazon EMR



Реляционные базы данных
Amazon RDS



Графовые базы данных
Amazon DynamoDB для БД Titan