ИНСТИТУТ
ЦИФРОВОГО
ОБРАЗОВАНИЯ
МГПУ

Big Data Analytics: Approaches and Tools

Московский городской педагогический университет

Лекция 6. Распределенная координация. Zookeeper

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Основные темы

- Особенности Zookeeper
- Архитектура
- Чтение/запись
- Пространство имен Zookeeper
- Отслеживание изменений (watch)
- Производительность

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Назначение и особенности Zookeeper

Zookeeper – координирующий сервис для распределенных приложений. Позволяет распределённым процессам координировать свои действия друг с другом

Предоставляет набор примитивов для реализации распределенного взаимодействия

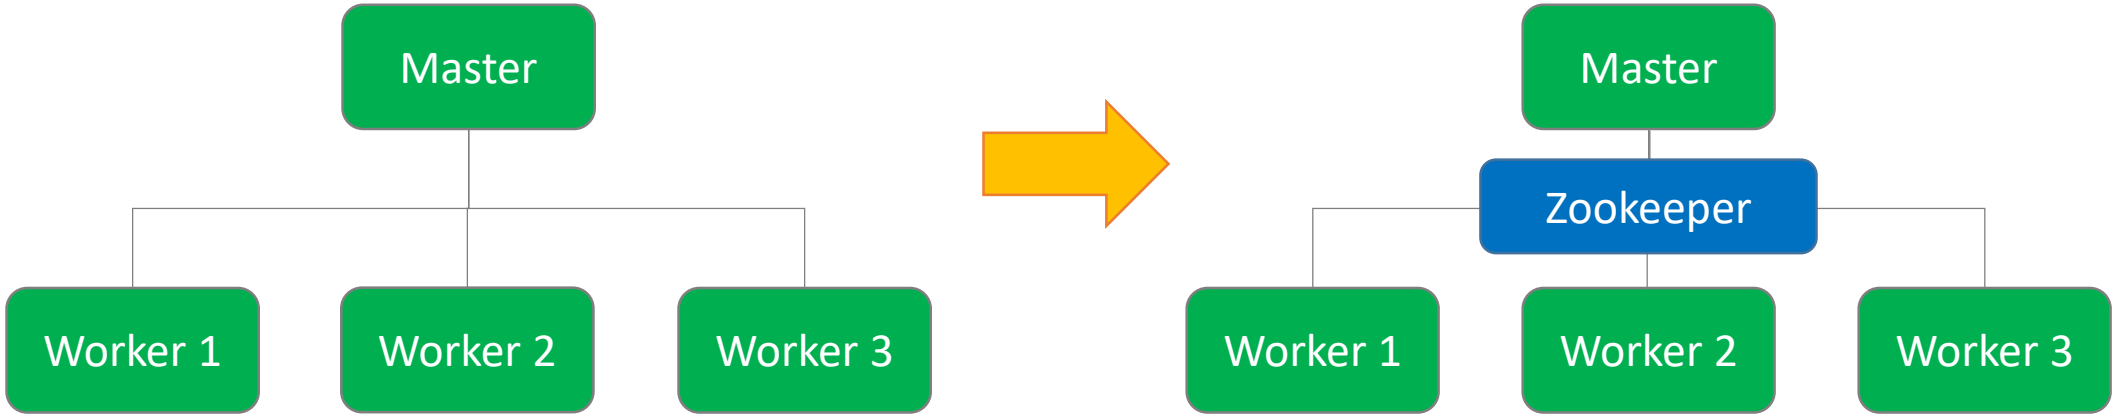

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Назначение и особенности Zookeeper

- Высокая пропускная способность (распределенная архитектура)
- Малые задержки (данные в оперативной памяти)
- Высокая надежность (репликации, выборы лидера)
- Строго упорядоченный доступ (идентификаторы операций)

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Словарь Zookeeper

- znode
- watch
- ensemble
- leader/follower
- Packet/proposal/message

Гарантии Zookeeper

- Последовательная согласованность (Sequential Consistency):
  изменения от клиента будут применены по порядке, в котором они были отправлены серверу

- Атомарность (Atomicity):
  изменения либо применяются целиком, либо нет. Невозможно частичное изменение

- Надежность (Reliability):
  Если изменения были приняты, то они сохранятся до следующего изменения клиентом

- X (Timeless):
  Клиент видит систему гарантированно актуальной в пределах определенного временного интервала

Назначение и особенности Zookeeper

- **Zookeeper** поддерживает разделяемое иерархическое пространство имен
- пространство имен состоит из регистров данных – **znode**
- **znode** может по аналогии с файловой системой выполнять одновременно роль файла и папки
- данные хранятся в оперативной памяти
- данные копируются на множество узлов, называемых ансамблем (**ensemble**)
- Zookeeper больше ориентирован на чтение, чем на запись в пропорции 10:1
- Клиенты – тысячи узлов

znode

- Каждый узел в пространстве имен может одновременно иметь данные, ассоциируемые с ним, и дочерние znode’ы
- Используется для хранения координирующих данных:
  - Информацию о статусах
  - Конфигурации
  - Информацию о размещении

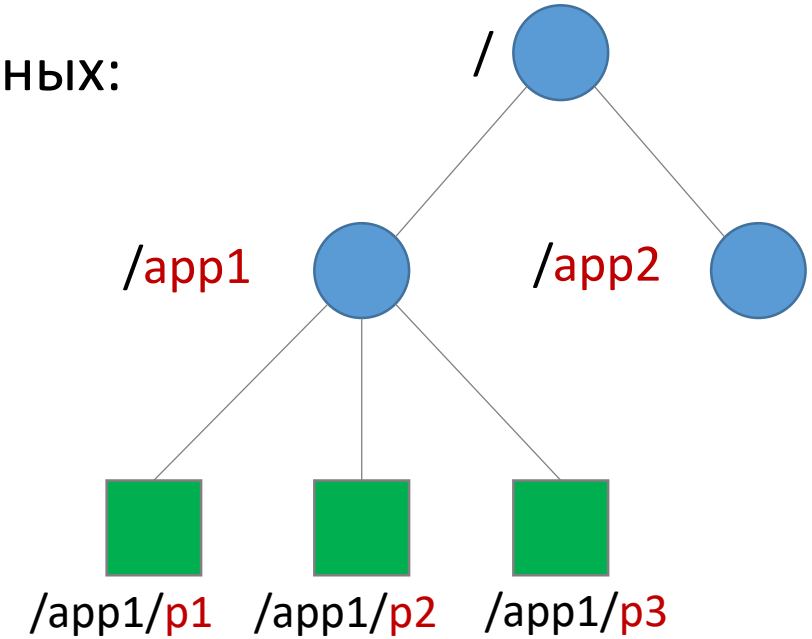

- Данные каждого узла, как правило, небольшого размера (B - KB)

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Атомарность чтения/записи

Данные **znode** читаются и записываются атомарно:

- при чтении можно получить только все данные **znode**
- при записи все данные **znode** заменяются новыми

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Эфемерный znode

Эфемерный (ephemeral) **узел** – znode, который существует на протяжении активной сессии, создавшей его. Когда сессия завершается, узел удаляется

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Параметры **znode**

czxid – zxid при создании

mzxid – zxid последнего изменения

ctime – время в миллисекундах от эпохи создания znode

mtime – от последнего изменения

version – количество изменений данных znode

cversion – количество изменений дочерних узлов

aversion – количество изменений в acl

ephemeralOwner – id сессии владельца znode, если это эфемерный **znode**. Если нет, то 0

dataLength – размер данных znode

numChildren – количество дочерних znode’ов

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Пример распределённого приложения

- Выбор мастера (Master election)

  Назначение задач worker’ам

- Обнаружение отказа (Crash detection)

  Мастер должен уметь определять, что worker вышел из строя или с ним потеряно соединение

- Управление группами (Group membership management)

  Мастер должен знать, какие worker’ы доступны для выполнения задач

- Управление метаданными (Metadata management)

  Мастер и worker’ы должны хранить задания и статусы выполнения надёжным способом

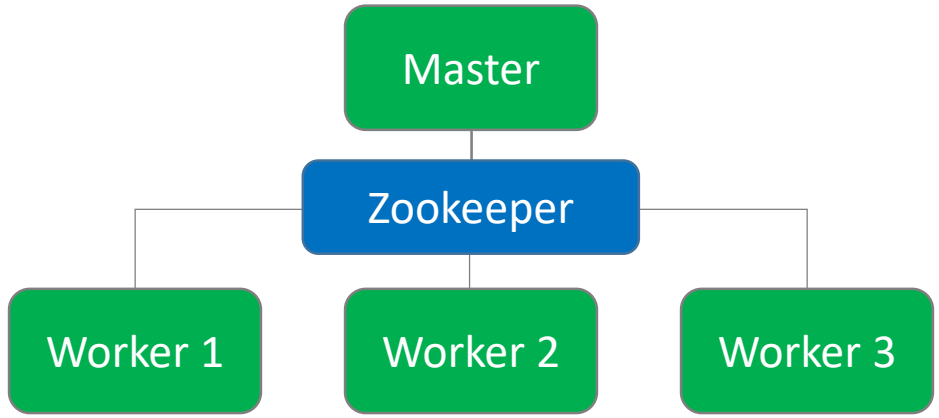

Пример распределённого приложения

/master znode содержит данные о мастере

/workers znode – родительский znode для всех znode'ов, соответствующих доступным worker'ам в системе. Если worker становится недоступным, то znode должен быть удален из /workers

/tasks znode – родительский znode для всех созданных задач, ожидающих выполнения на worker'ах

/assign znode – родительский znode для распределённых по worker'ам задач

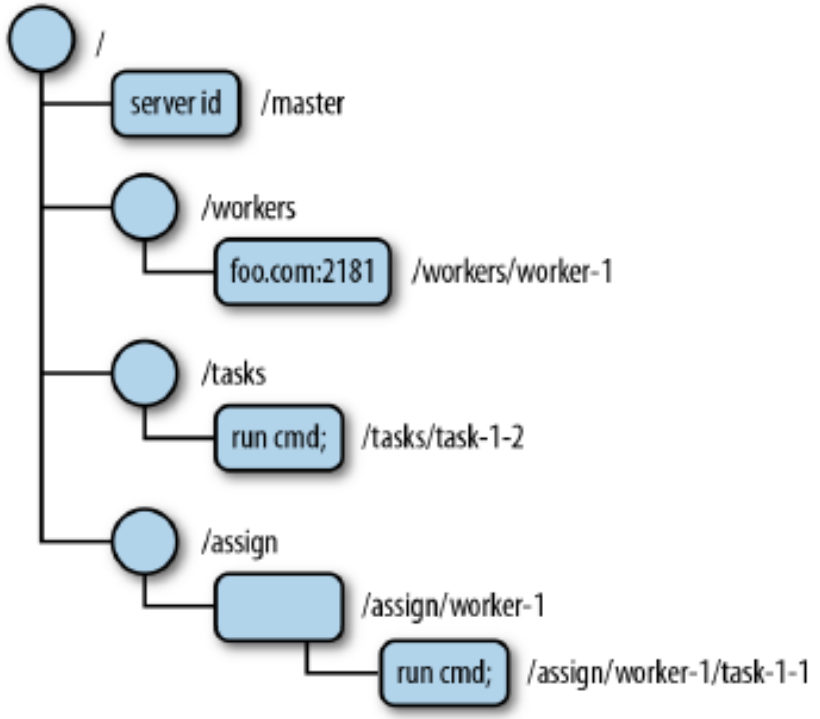

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Архитектура Zookeeper

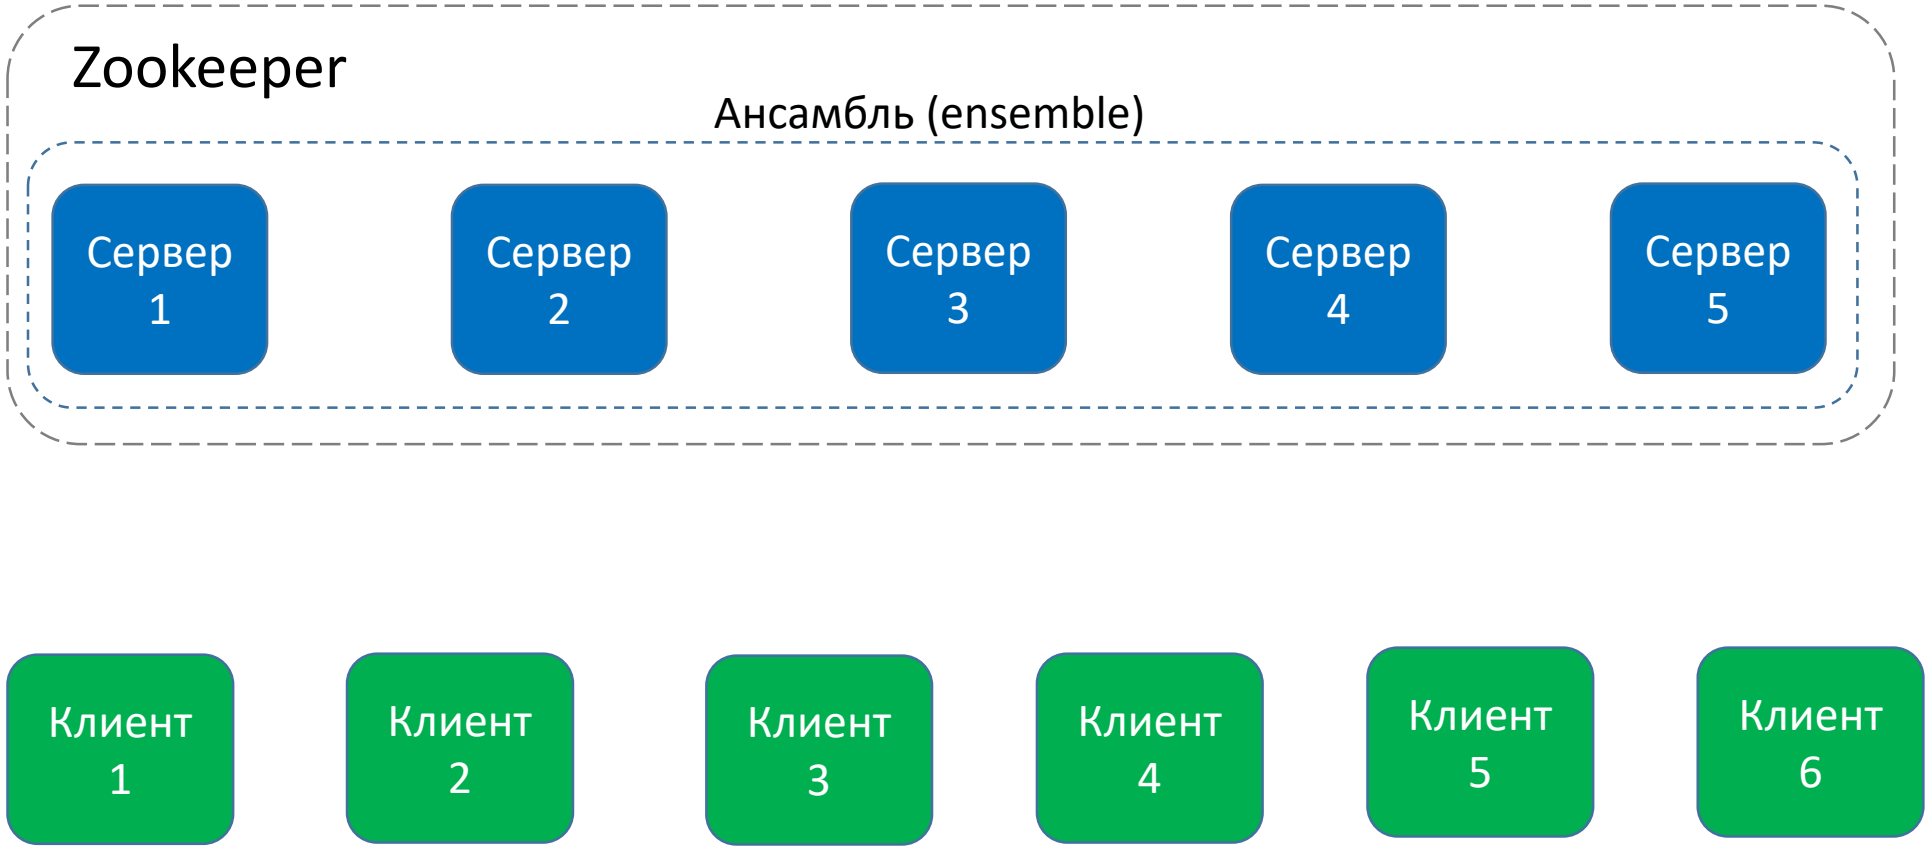

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Архитектура Zookeeper

- Все серверы Zookeeper знают друг о друге
- Поддерживают:
  - Образ состояния (в оперативной памяти)
  - Логи транзакций (в постоянной памяти)
  - Снепшот (в постоянной памяти)

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Архитектура Zookeeper. Типы серверов

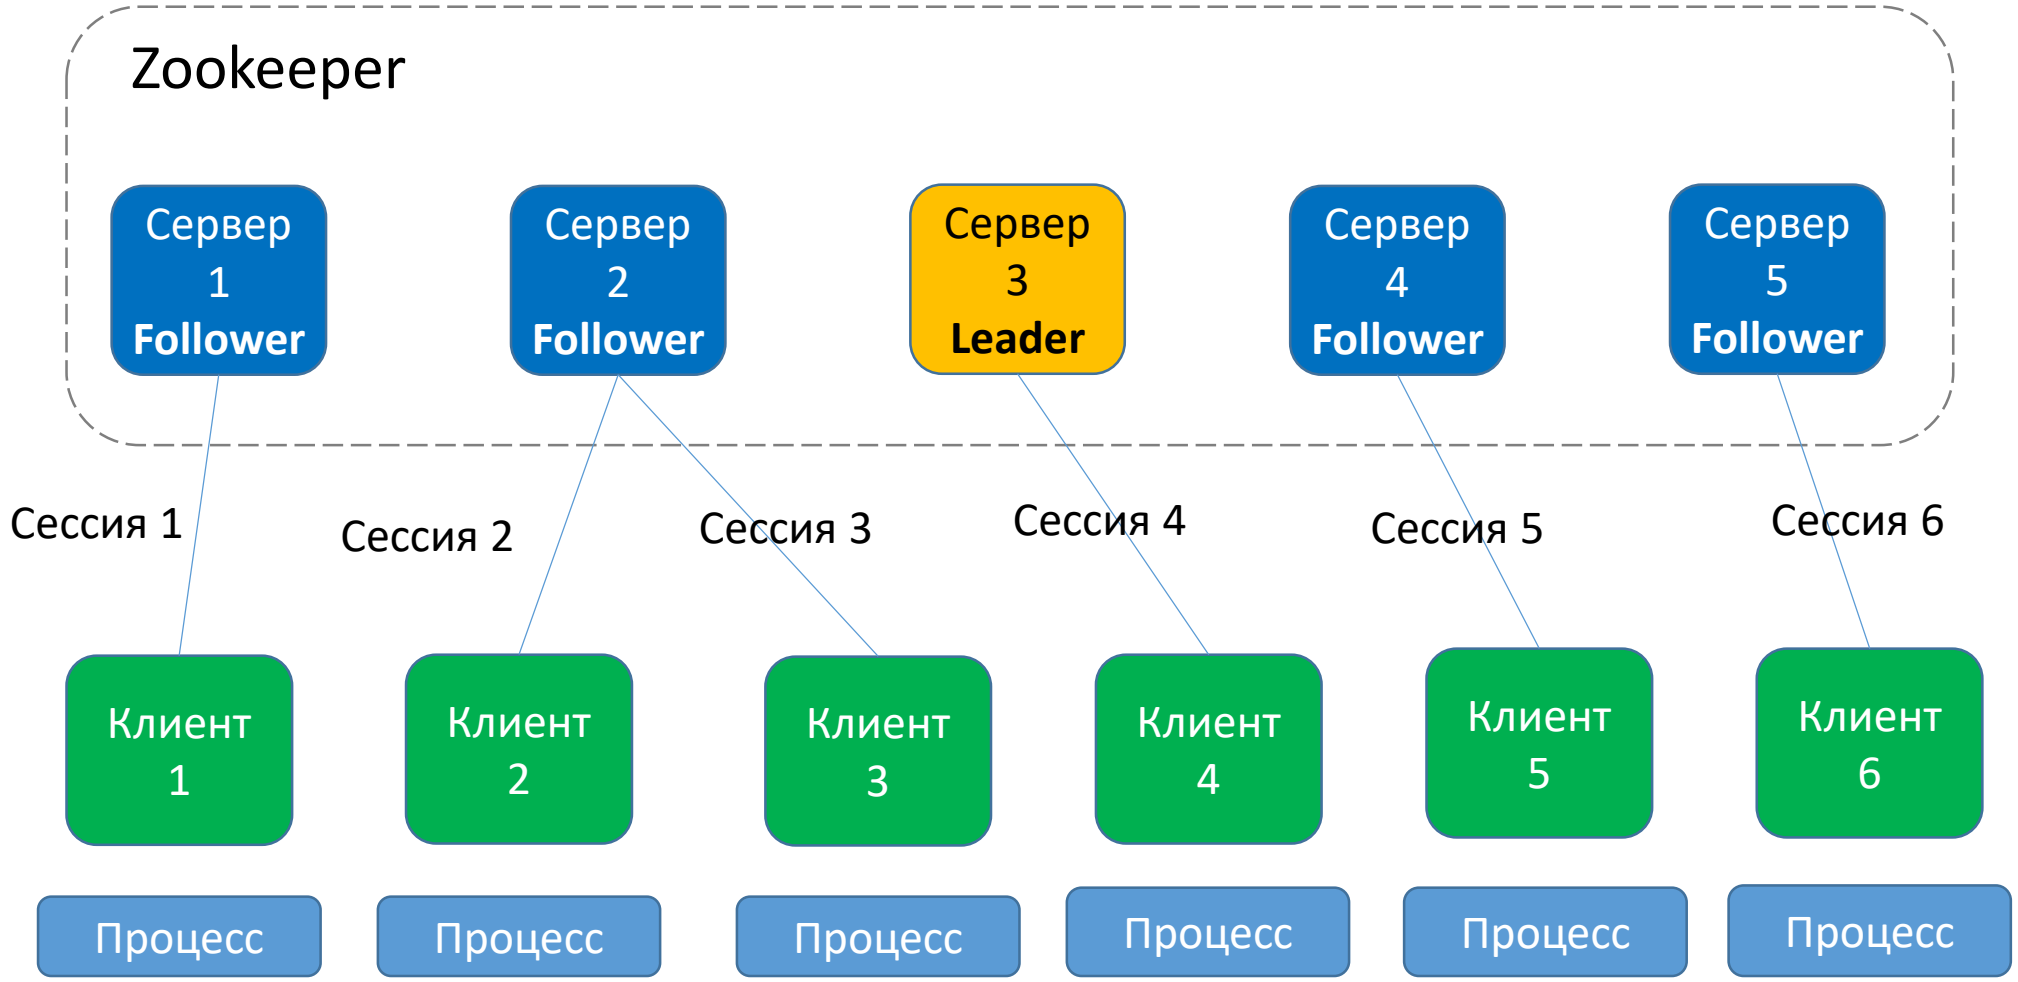

Распределенное приложение

Архитектура Zookeeper. Клиент-Сервер

Соединения между Клиентом и Сервером используется для:

- Отправки запросов
- Получения ответов
- Отслеживания событий
- Отправки heartbeat

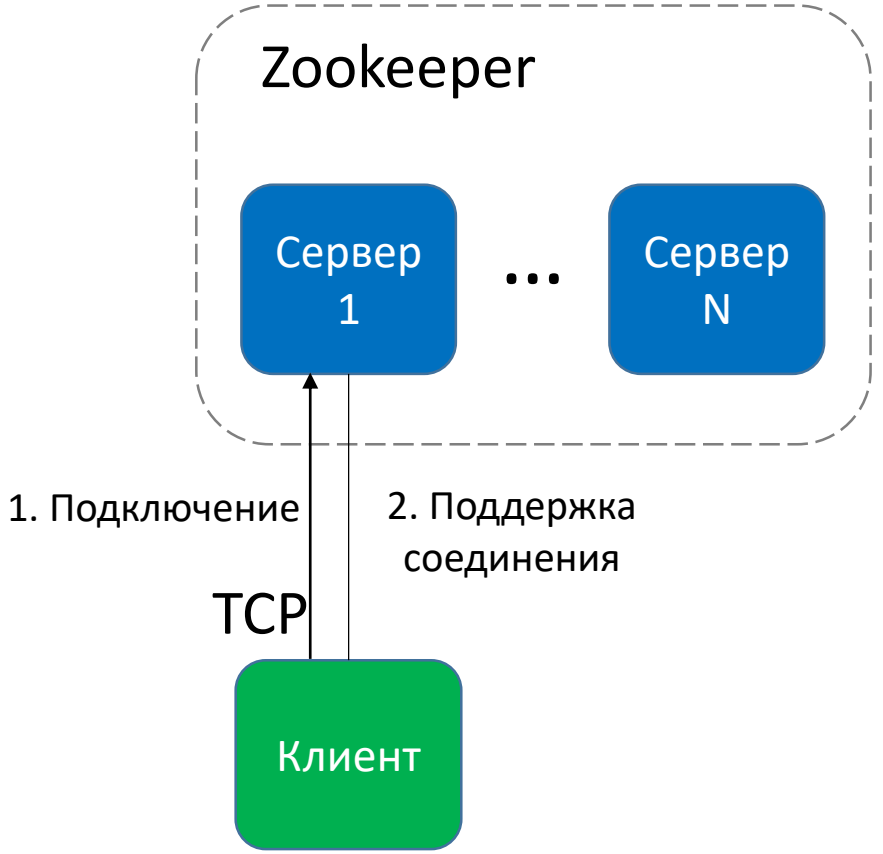

Архитектура Zookeeper. Запись/Чтение

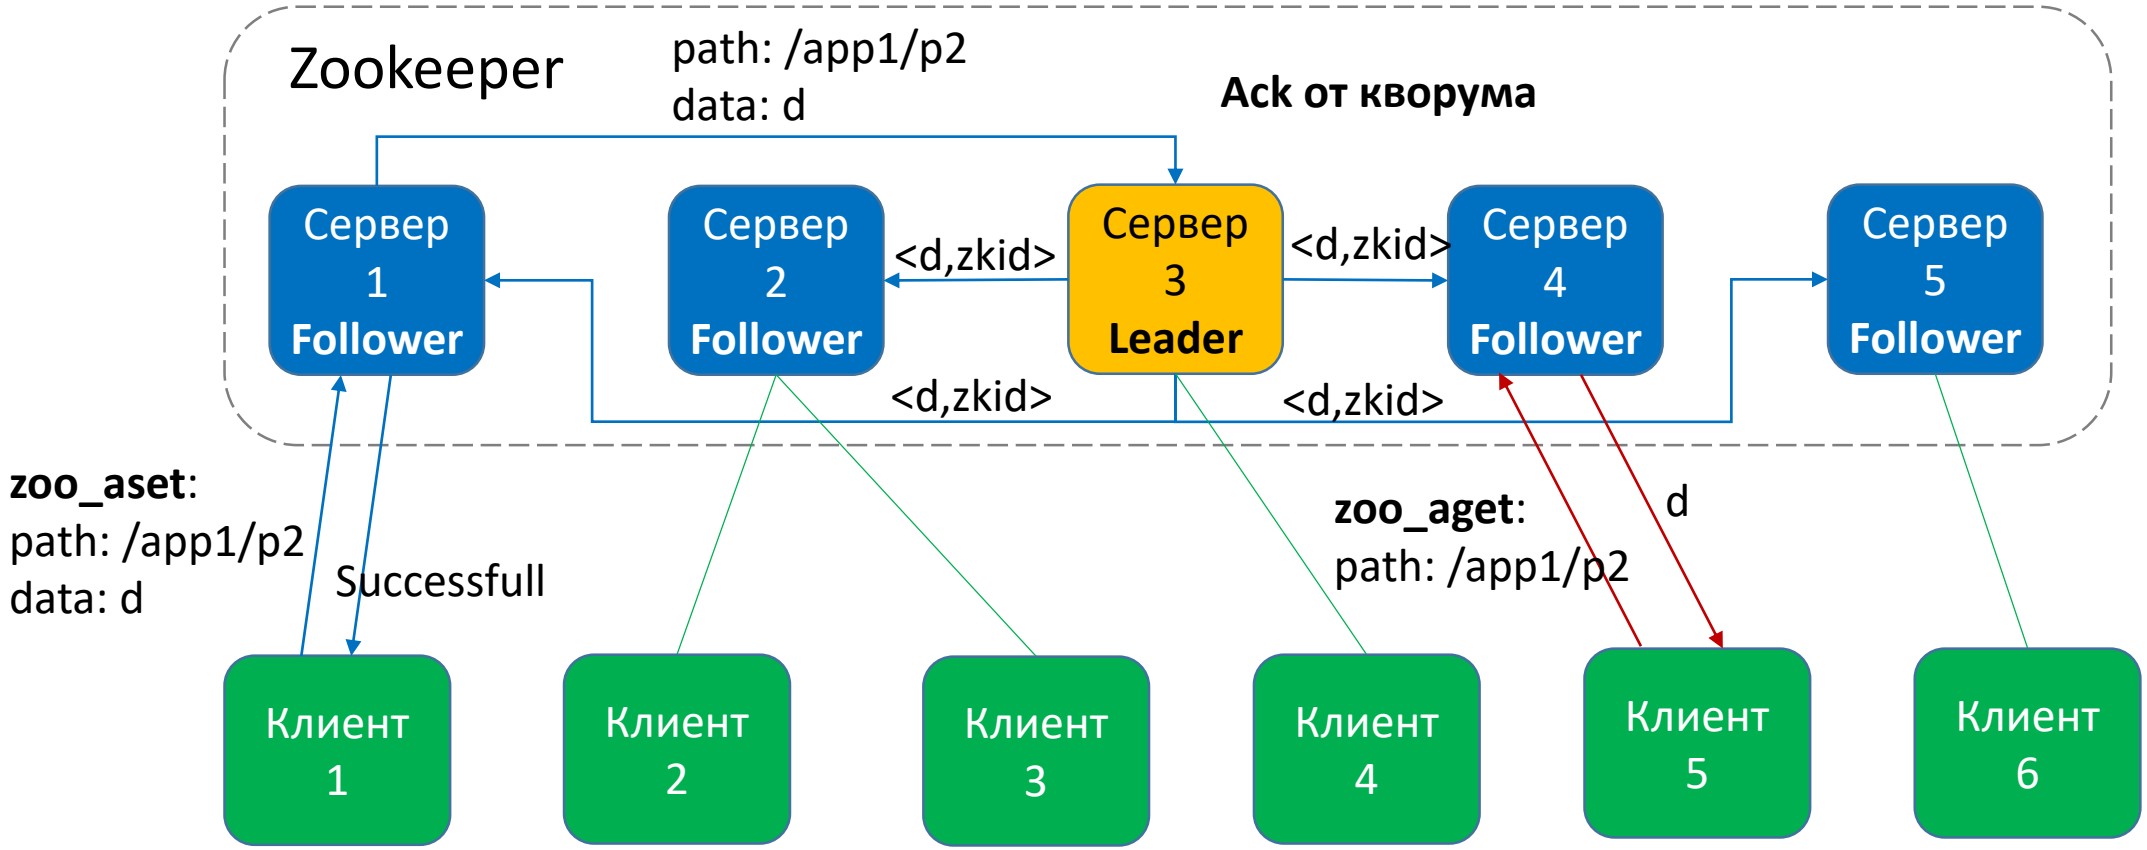

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Свойства Атомарной системы сообщений (Atomic Broadcast)

- Надежная доставка (Reliable delivery)
  Если сообщение m доставлено одним сервером, оно будет доставлено в конечном счете всеми серверами

- Total order

- Casual order

Архитектура Zookeeper. Сервер

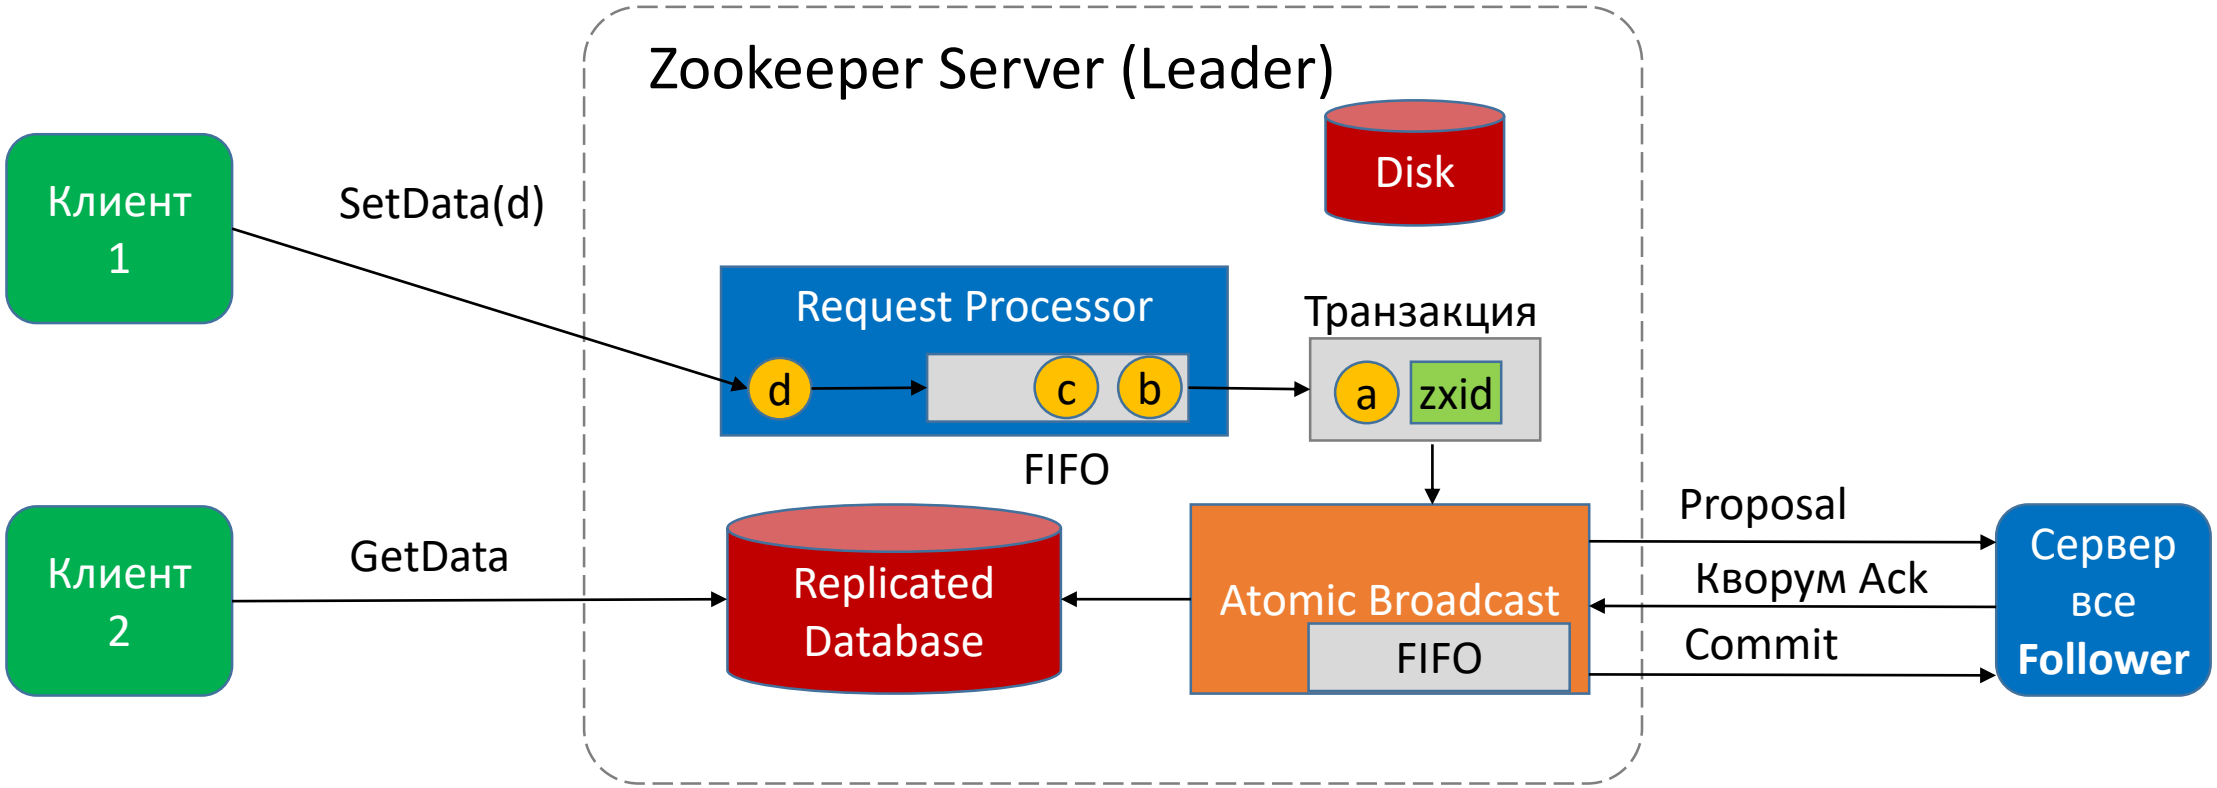

Replicated Database – база данных всего дерева пространства имен (в оперативной памяти)

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Свойства Атомарной системы сообщений (Atomic Broadcast)

- **Packet**
  Последовательность байтов, отправленных через FIFO канал

- **Proposal**
  Единица согласования. Proposal обмениваются пакетами с кворумом серверов. Proposal, как правило, содержат message (кроме NEW_LEADER)

- **Message**
  Последовательность байтов, которая атомарно распространяется на все серверы. Message кладется в proposal и согласуется перед доставкой

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Свойства Атомарной системы сообщений (Atomic Broadcast)

Обмен сообщениями состоит из двух фаз:

- Активация лидера (Leader activation)
  Лидер устанавливает корректное состояние системы и готов начать создавать proposal

- Активный обмен сообщениями (Active messaging)
  Лидер берет messages, чтобы предложить и координировать доставку сообщений

Программный интерфейс

Zookeeper поддерживает следующие операции:

- **Create** создает узел (**znode**) в пространстве имен
- **Delete** удаляет узел
- **Exists** проверяет существует ли узел по пути
- **Get data** читает данные из узла
- **Set data** записывает данные в узел
- **Get children** возвращает список дочерних узлов
- **Sync** ожидает пока данные будут распределены между Zookeeper серверами

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Контроль доступа Zookeeper

- CREATE: можно создавать дочерние узлы
- READ: можно получить данные от узла и список детей
- WRITE: можно записывать данные в узел
- DELETE: можно удалять дочерние узлы
- ADMIN: можно устанавливать разрешения

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Watches

- Клиент может установить наблюдение (watch) на **znode**
- Если **znode** изменится, то клиент получит уведомление
- После уведомления **watch** сбрасывается
- Также **watch** уведомляет клиента, если потеряно соединение с сервером Zookeeper (на стороне клиента)

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Watch на изменение данных. Проблема

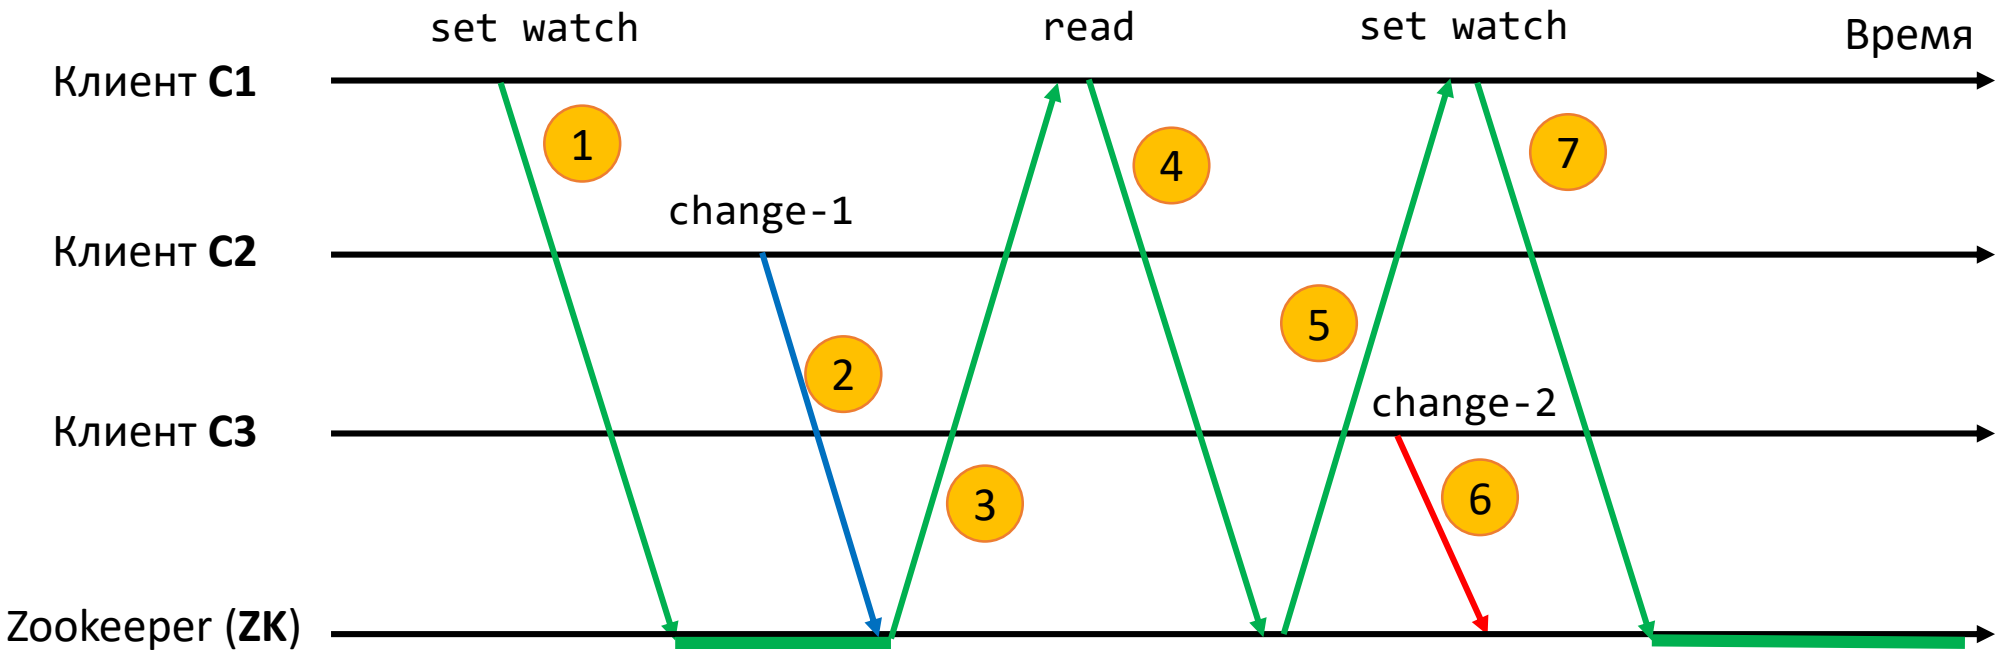

C1 не узнает об изменении **change-2**

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Watch на изменение данных. Решение

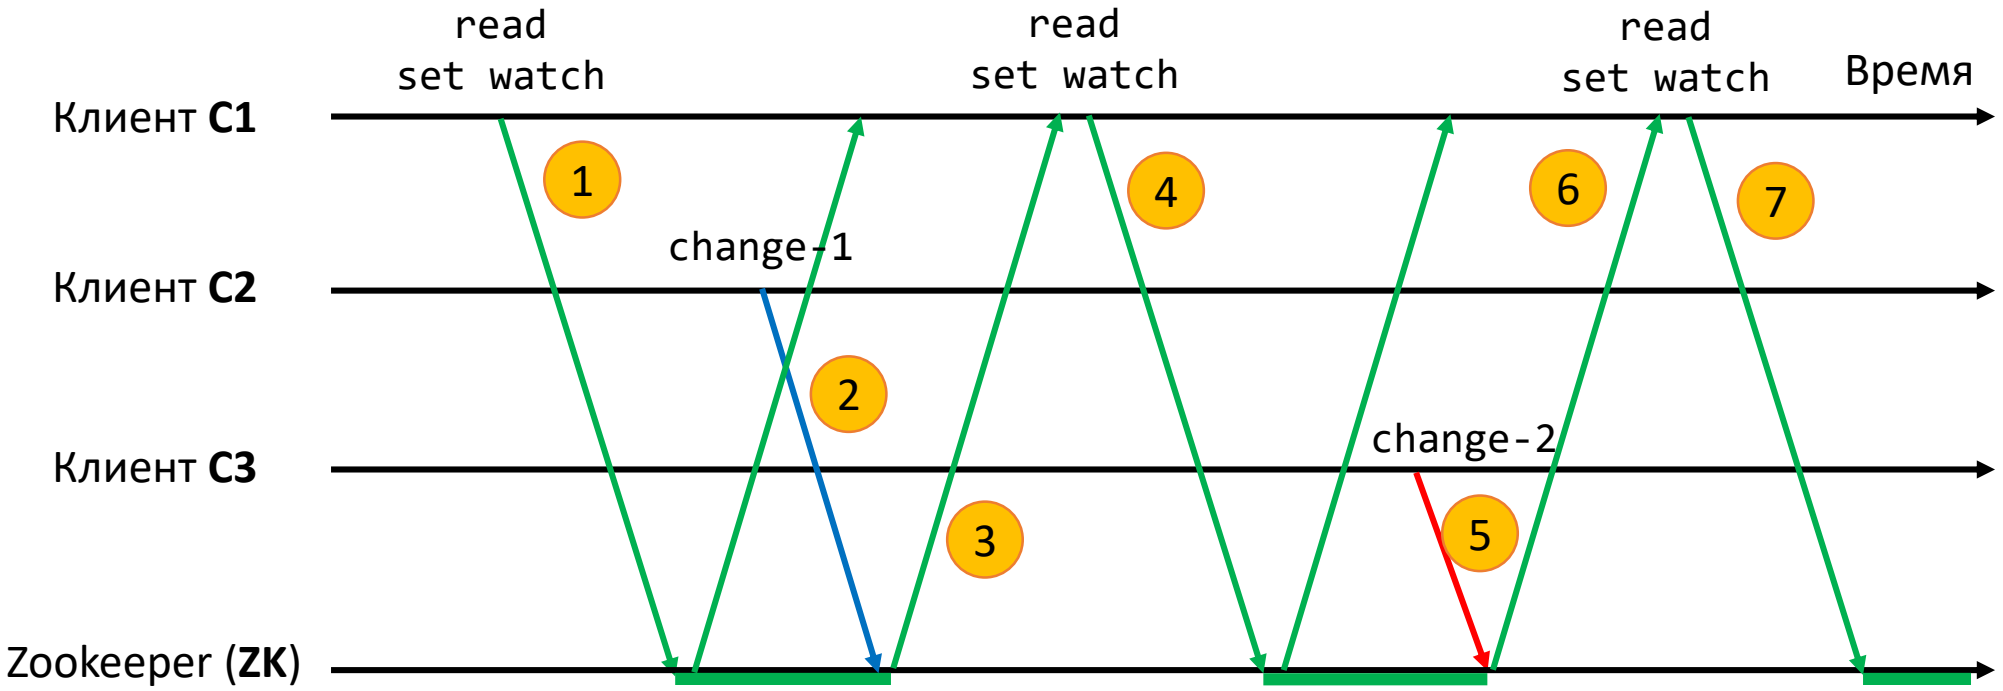

C1 узнает об изменении **change-2**

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Watch на изменение данных. Решение

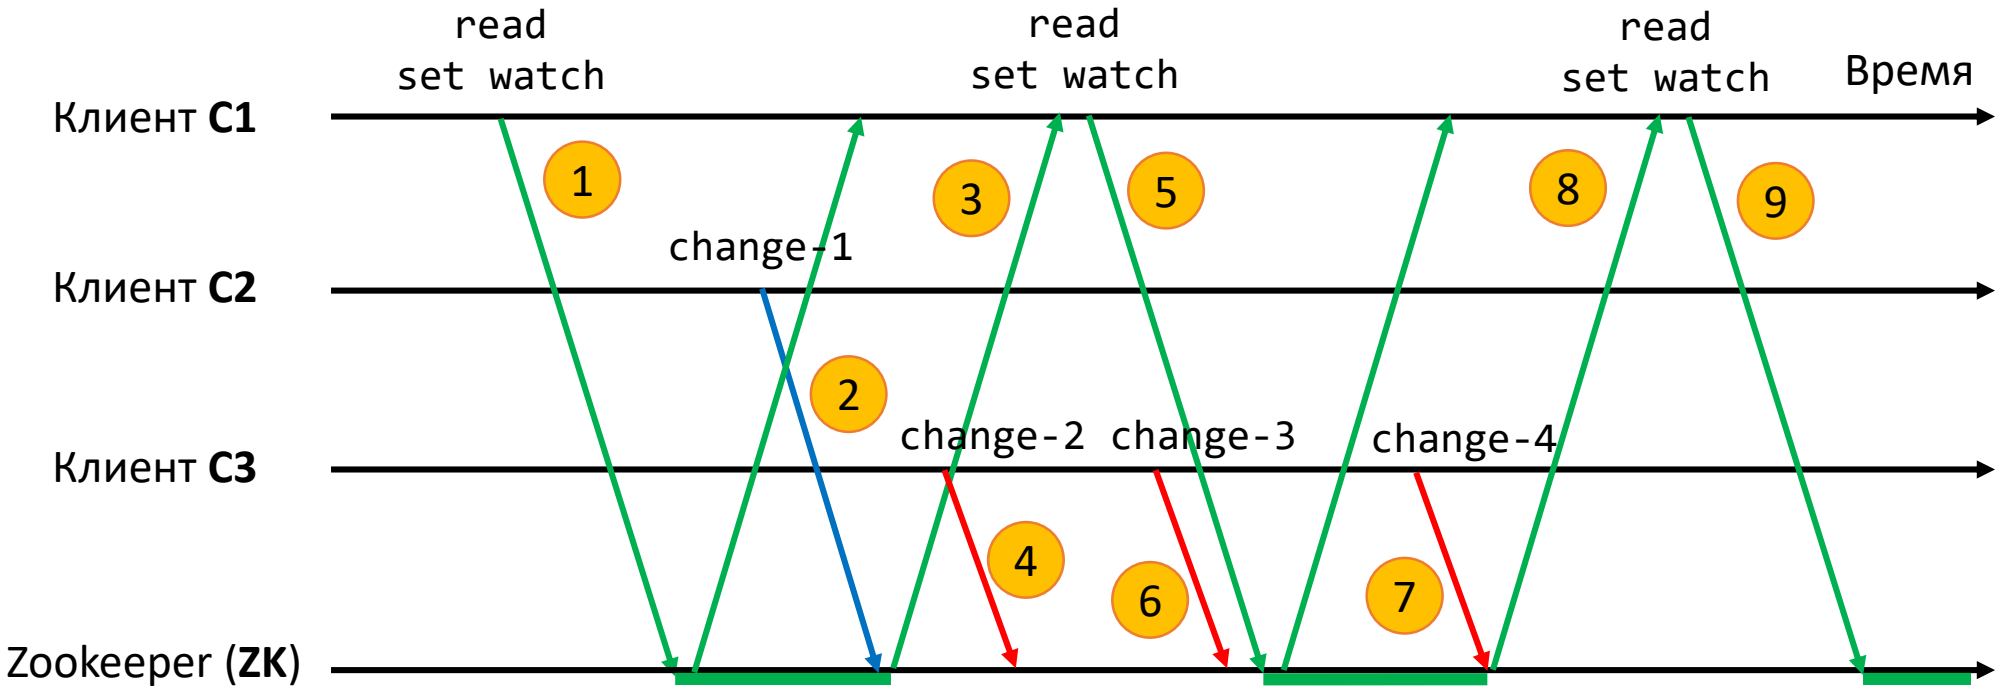

- **C1** не получит уведомления об изменениях **change-2** и **change-3**
- однако **C1** получит состояние после внесения изменения **change-3** при чтении (шаг 5)

Watches

Watch устанавливаются вместе с операциями **getData()**, **getChildren() и exists()**

WatchedEvent

- KeeperState
- EventType
- path

WatcherType

- Children
- Data
- Any

EventType

- None (-1),
- NodeCreated (1) (exists),
- NodeDeleted (2) (exists, getData),
- NodeDataChanged (3) (exists, getData),
- NodeChildrenChanged (4) (getChildren);

KeeperState

- Unknown (-1)
- Disconnected (0)
- NoSyncConnected (1)
- SyncConnected (3)
- AuthFailed (4)
- ConnectedReadOnly (5)
- SaslAuthenticated (6);
- Expired (-112);

https://github.com/apache/zookeeper/tree/master/zookeeper-server/src/main/java/org/apache/zookeeper

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Watch на изменение данных. getChildren()

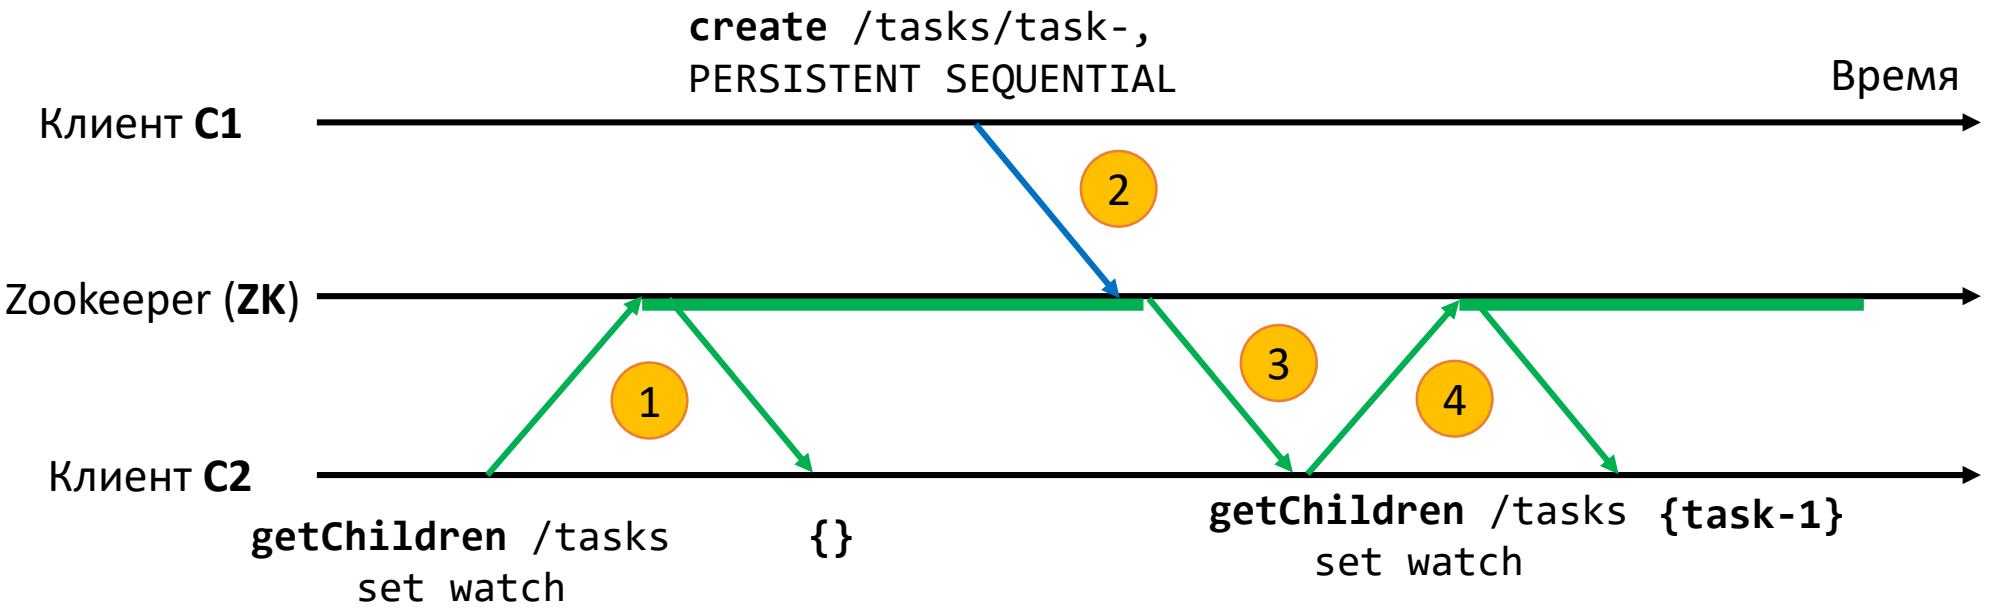

1. **C2** запрашивает список заданий + ставит **watch** на изменения. Получает список (пустой)
2. **C1** создает задание
3. Срабатывает установленный **watch** и **C1** получает уведомление об изменении
4. **C2** запрашивает список заданий + ставит **watch** на изменения. Видит новое задание

Повторное подключение. Session timeout

Session timeout (**T**) – период времени, в течение которого существует сессия и соединение может быть восстановлено без установки новой сессии. После этого периода сессия истекает (expired).

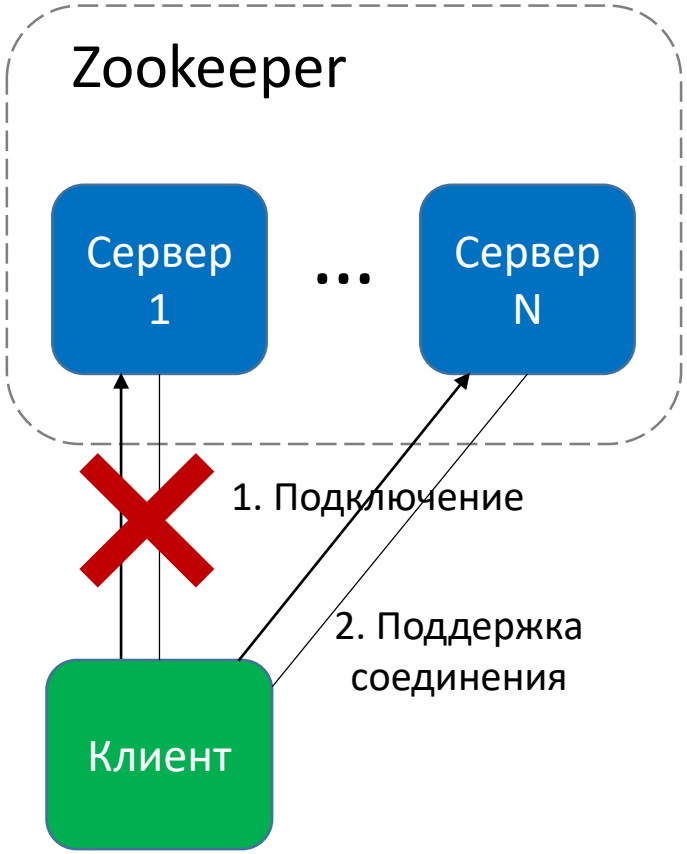

- Если в течение **T** сервер не получает сообщение от клиента, то сессия истекает
- Если клиент не может получить ответ от сервера в течение 1/3 от **T**, то он посылает heartbeat сообщение серверу
- Начиная с 2/3 от **T** клиент пытается найти другой сервер. У него на это есть 1/3 от **T**
- Сервер удаляет эфемерные узлы, созданные клиентом, отправляет уведомления другим клиентам и пр.
- После повторной установки соединения клиент получает уведомление об истечении сессии от сервера

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Повторное подключение. Пример

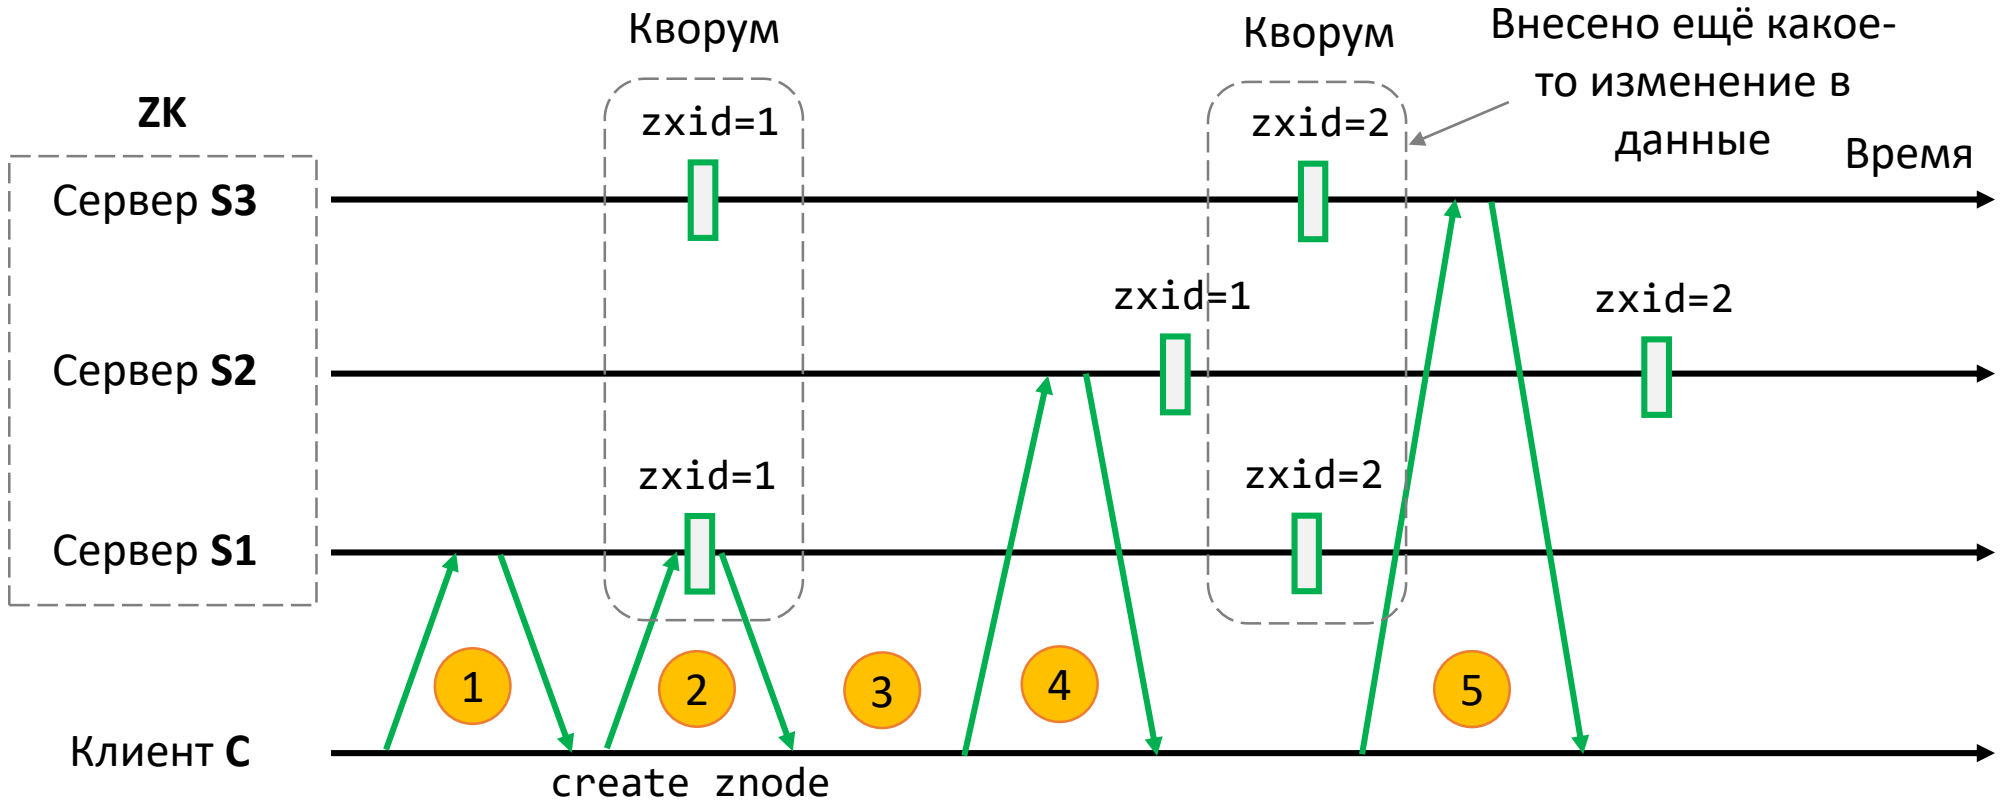

1. **C** подключается к **S1**
2. **C** выполняет **create** операцию, которой соответствует транзакция **zxid=1**
3. **C** теряет соединение с **S1**
4. **C** пытается подключиться к **S2**, но сервер имеет **zxid** меньше 1
5. **C** подключается к **S3**

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Восстановление соединения

- При восстановлении соединения восстанавливаются (клиентом) также **watches** на новом сервере
- Когда клиент подключается к серверу ZK, он отправляет список watches и последний zxid, который он видел
- Сервер просматривает временные метки последних изменений соответствующих znode. Если есть новые изменения, то сервер отправит клиенту уведомление, т.е. сработает watch

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Восстановление соединения. Проблема exists()

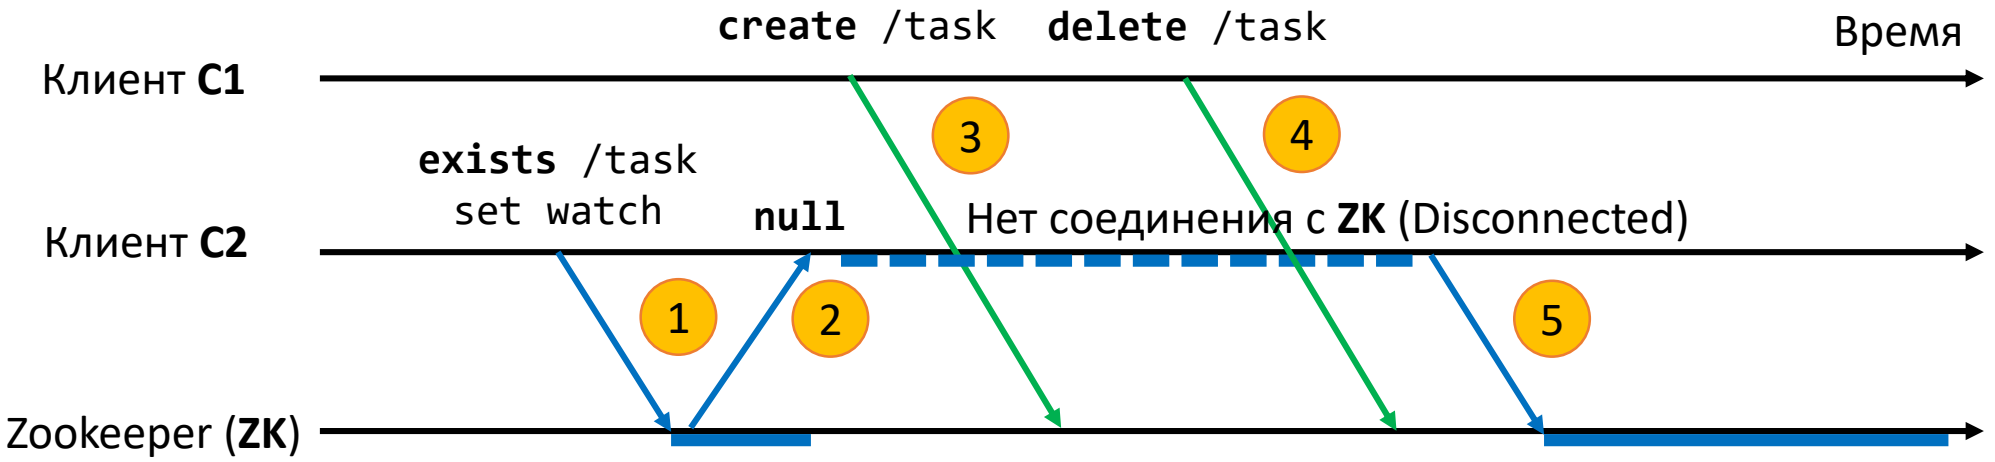

1. **C2** запрашивает существование **/task** + ставит **watch** на изменения. Получает ответ, что /task не существует
2. **C2** теряет соединение с **ZK**
3. **C1** создает **/task**
4. **C1** удаляет **/task**
4. **C2** восстанавливает соединение и **watch** на **/task**. **Watch** не срабатывает и **C2** не узнает о шагах 3 и 4

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Версия znode

- Каждый **znode** имеет соответствующий ему номер версии
- Значение версии увеличивается на 1 при каждом изменении данных
- Операции с указанием версии: setData, delete
- Операция выполняется, только если указанная версия соответствует текущей версии **znode** на сервере

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Версия znode. Запись с условием

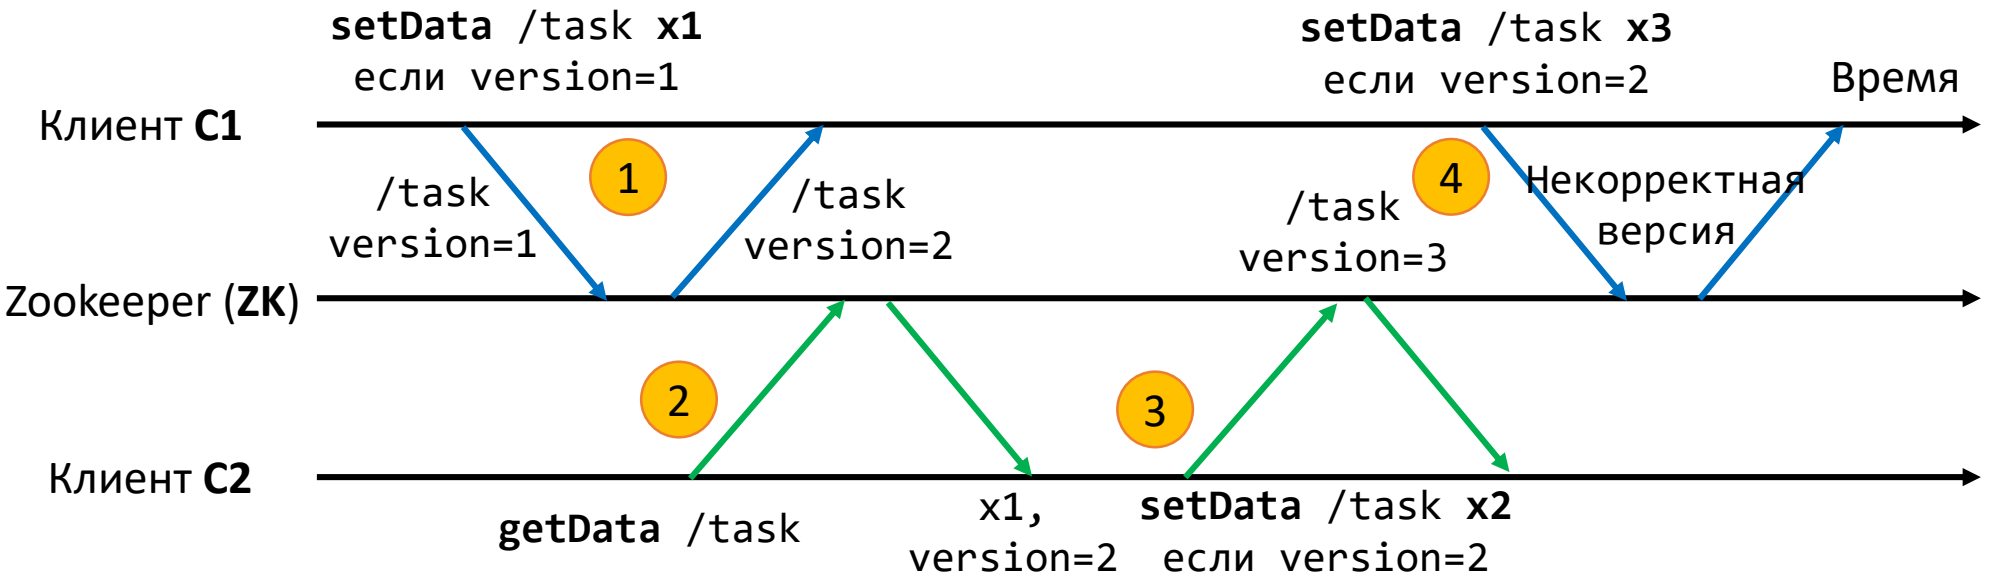

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Нарушение порядка. Скрытая передача

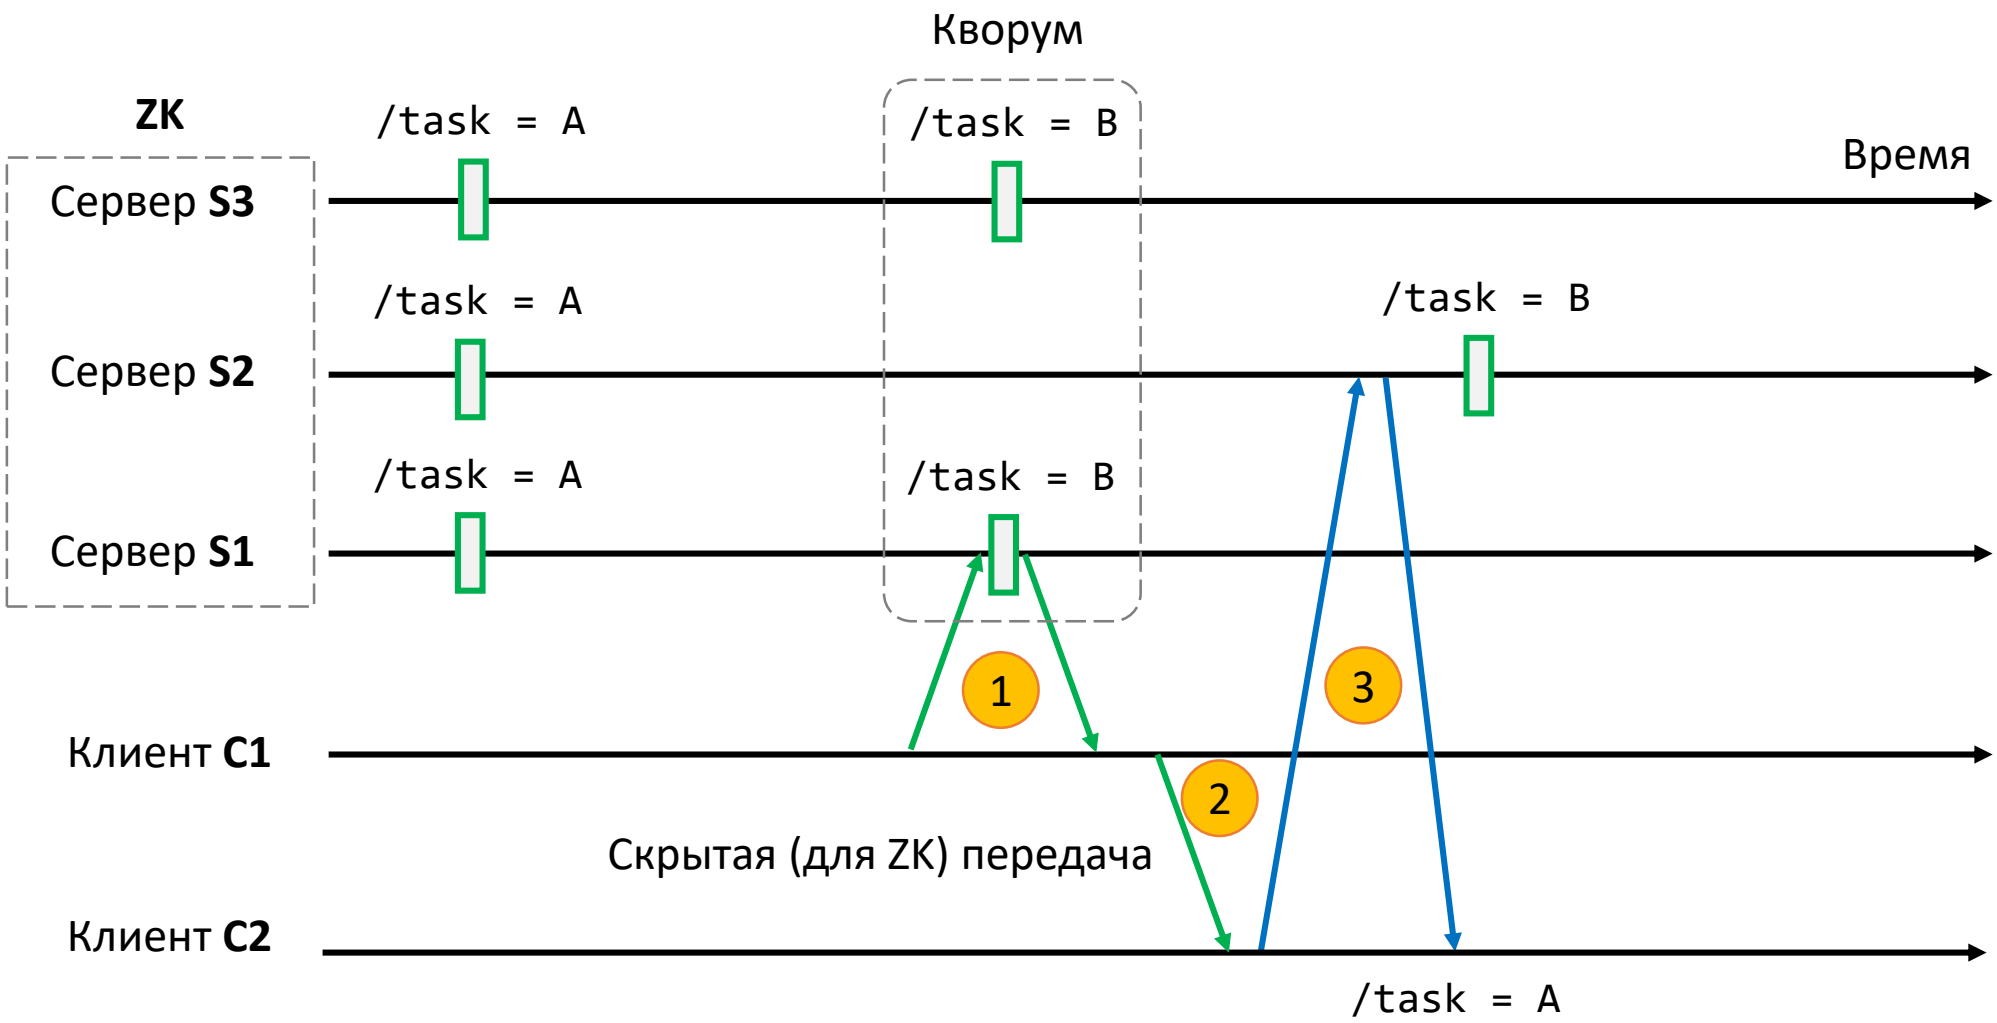

1. **C1** изменяет /task на **B**
2. **C1** сообщает **C2** в обход **ZK**, что изменилась задача
3. **C2** запрашивает новую задачу, но получает и обрабатывает старый вариант

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Нарушение порядка. Пример с двумя мастерами

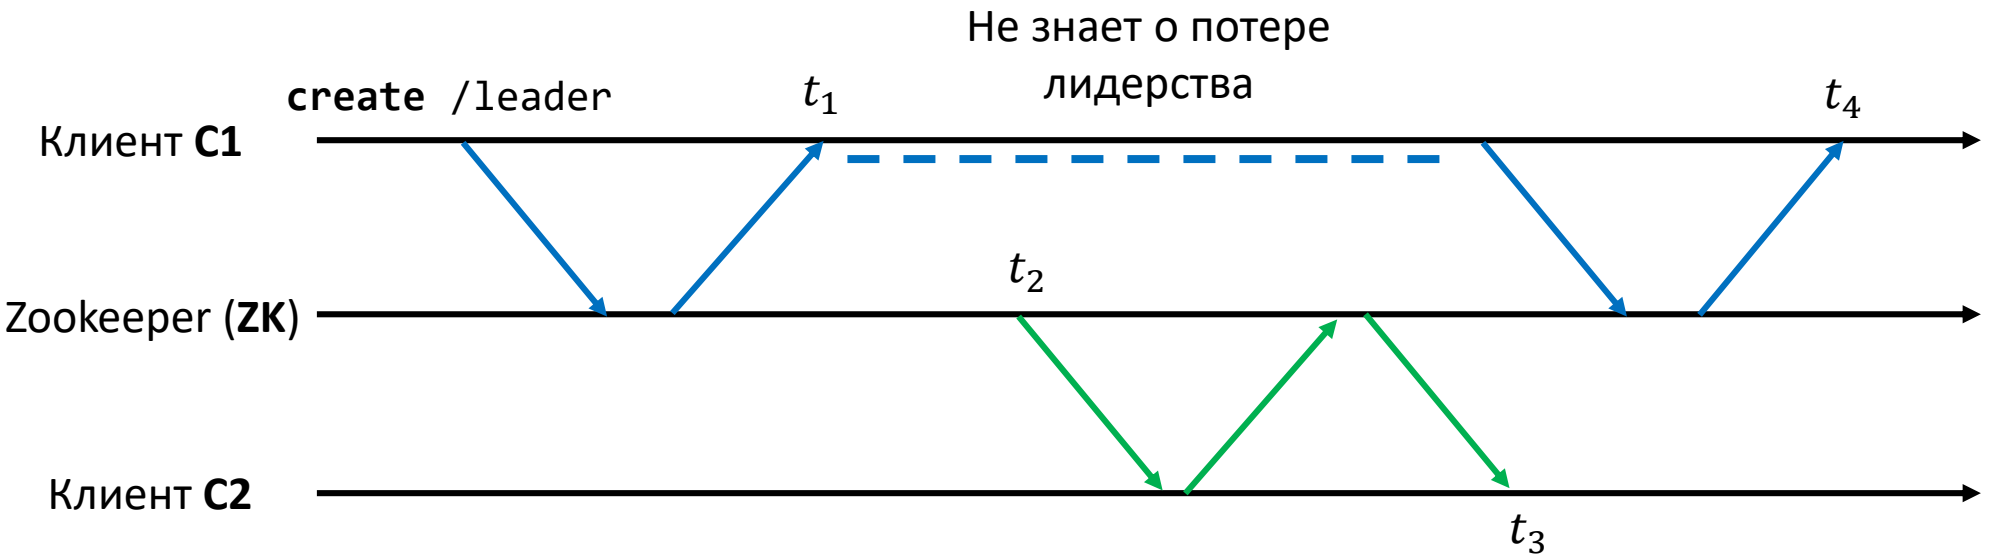

t_1 **C1** теряет соединение с **ZK**

t_2 **C2** уведомляется, что **C1** недоступен

t_3 **C2** становится лидером

t_4 **C1** повторно подключается к **ZK** и обнаруживает, что соединения истекло

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Нарушение порядка. Пример с двумя мастерами

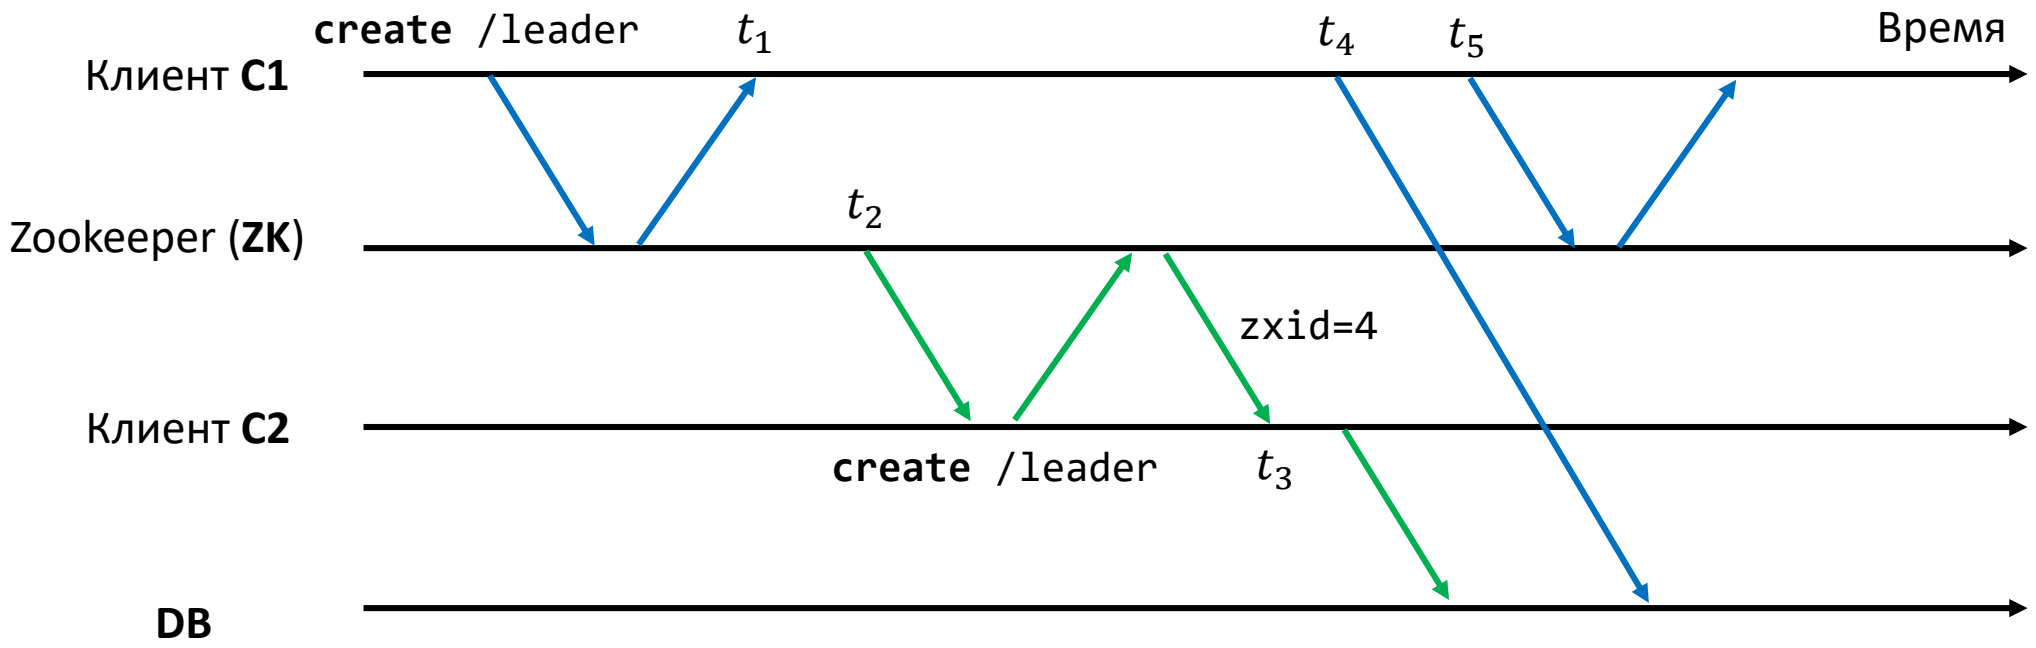

t_1 **C1** начинает **GC**

t_2 **ZK** определяет, что **C1** вышел из строя недоступен

t_3 **C2** становится лидером, синхронизируется с **DB** и обновляет данные

t_4 **C1** отправляет ранее подготовленные обновления отправляет в **DB**

t_5 **C1 повторно подключается к ZK** и обнаруживает, что сессия истекла

Пример. Выбор лидера

Алгоритм на клиентах

1. Создание эфемерного последовательного znode /election/n-i
2. Получение текущего списка дочерних узлов /election посредством getChildren() без watch
3. Если i наименьшее значение, то клиент становится лидером. Выборы завершаются и запускаются процедуры лидера
4. Проверяется exists() с watch на n-j, где j следующее от i наименьшее число znode из полученного списка дочерних узлов
5. Если false, то переход на шаг 2
6. Ожидание срабатывания watch на n-j, после этого переход на шаг 2.

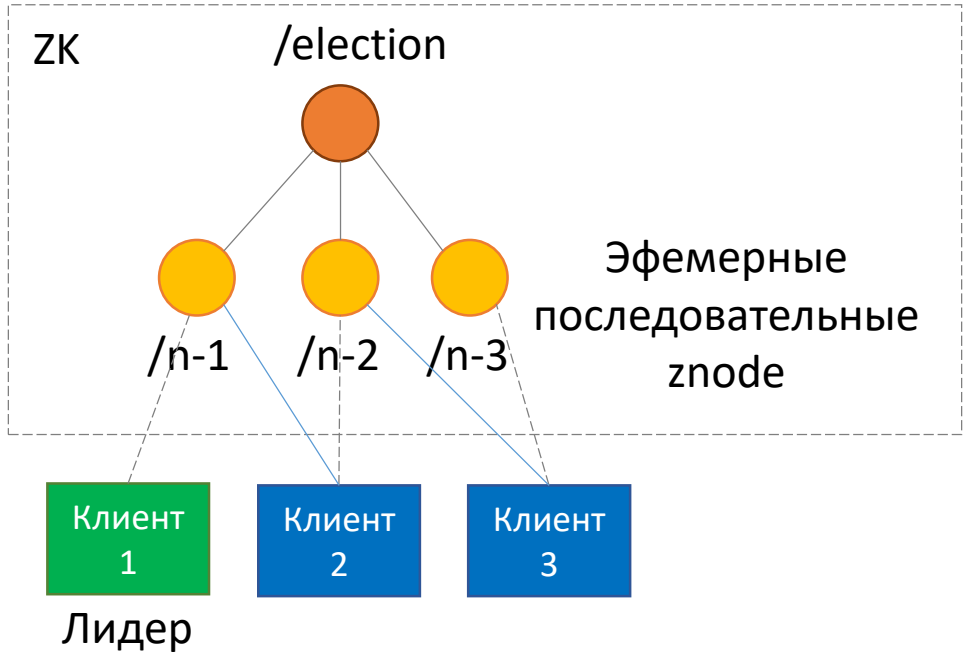

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Пример. Распределенная блокировка

Алгоритм на клиентах

1. Создание эфемерного последовательного znode /locknode/lock-i
2. Получение текущего списка дочерних узлов /locknode посредством getChildren() без watch
3. Если i наименьшее значение, то клиент получает lock и завершается протокол
4. Проверяется exists() с watch на lock-j, где j следующее от i наименьшее число znode из полученного списка дочерних узлов
5. Если false, то переход на шаг 2
6. Ожидание срабатывания watch на lock-j, после этого переход на шаг 2.

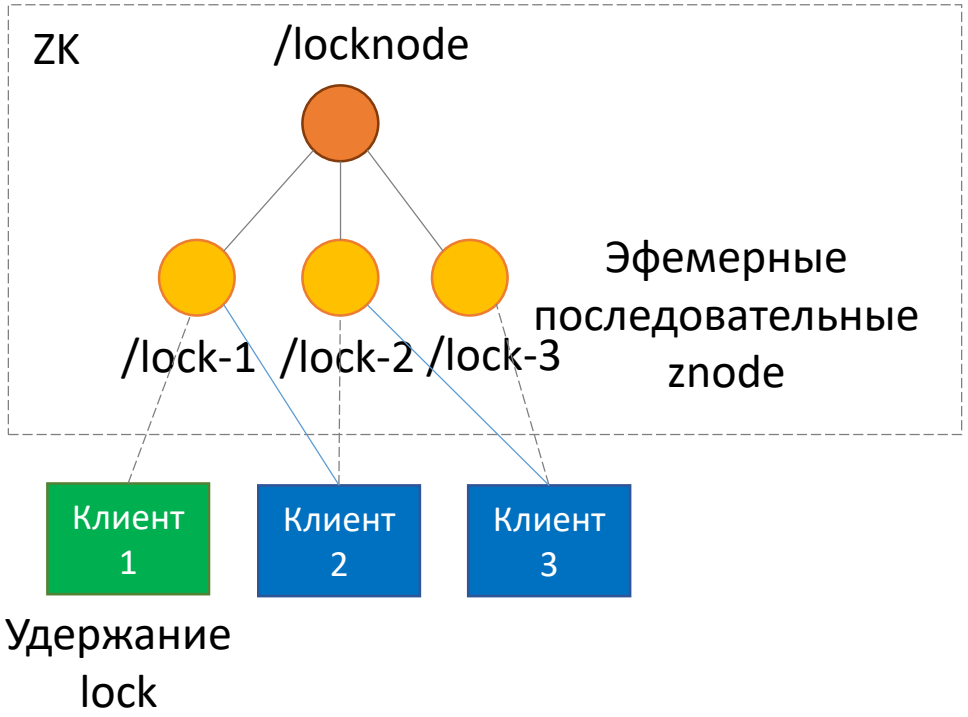

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Производительность Zookeeper. Чтение/запись

v3.1.1

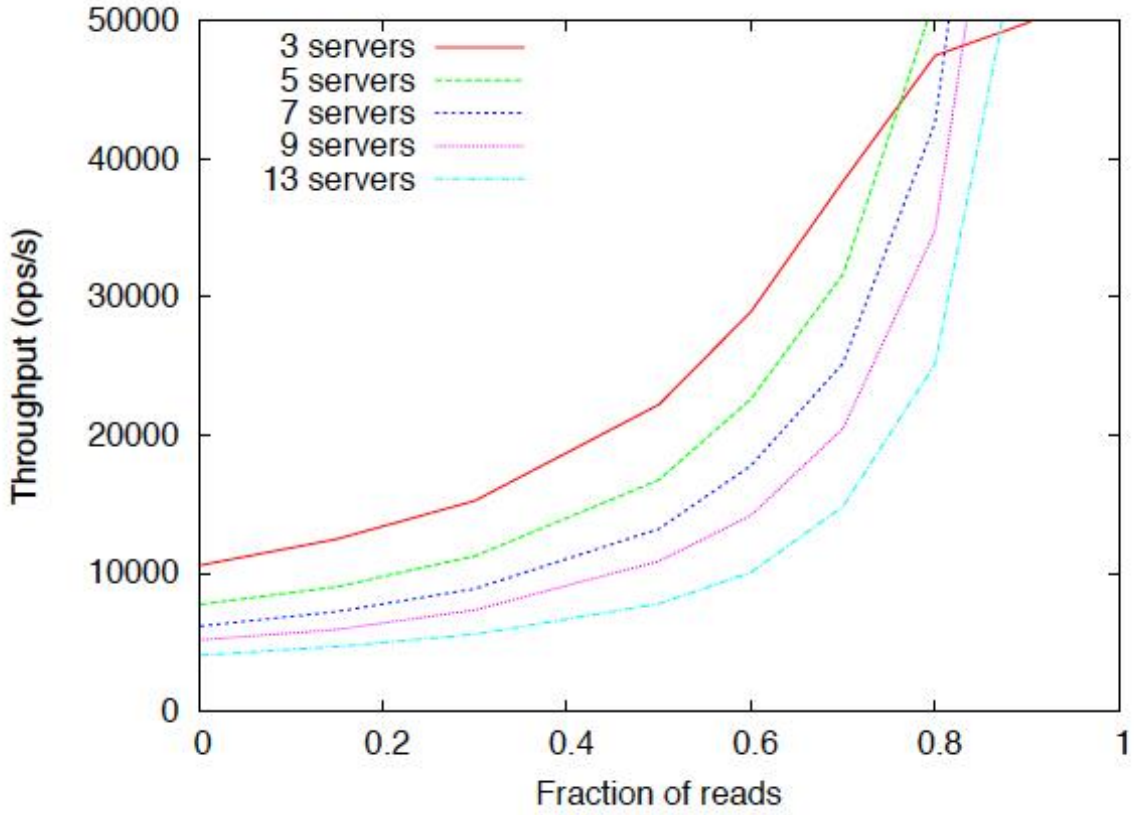

v3.3.5

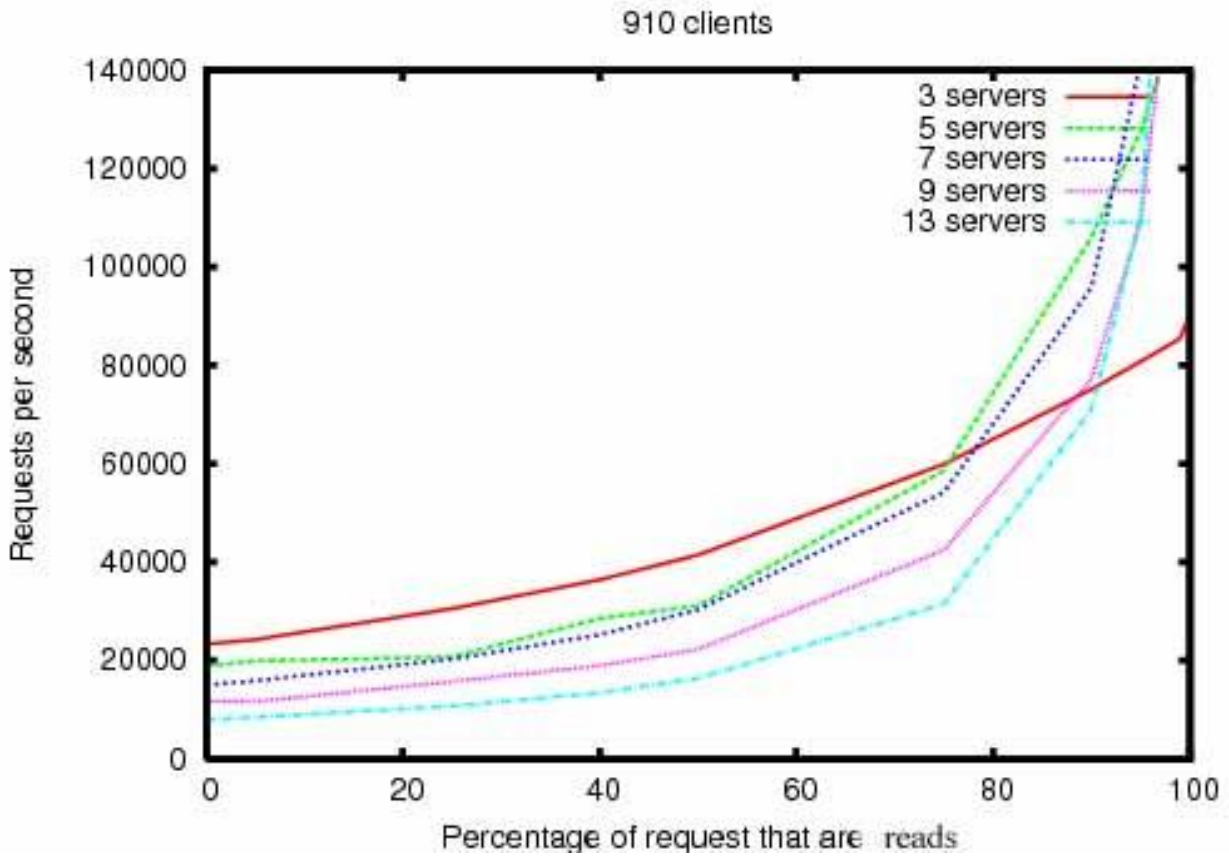

http://zookeeper.apache.org/doc/r3.1.1/zookeeperOver.html

http://zookeeper.apache.org/doc/r3.3.5/zookeeperOver.html

Производительность при сбоях

7 серверов
Запись 30%

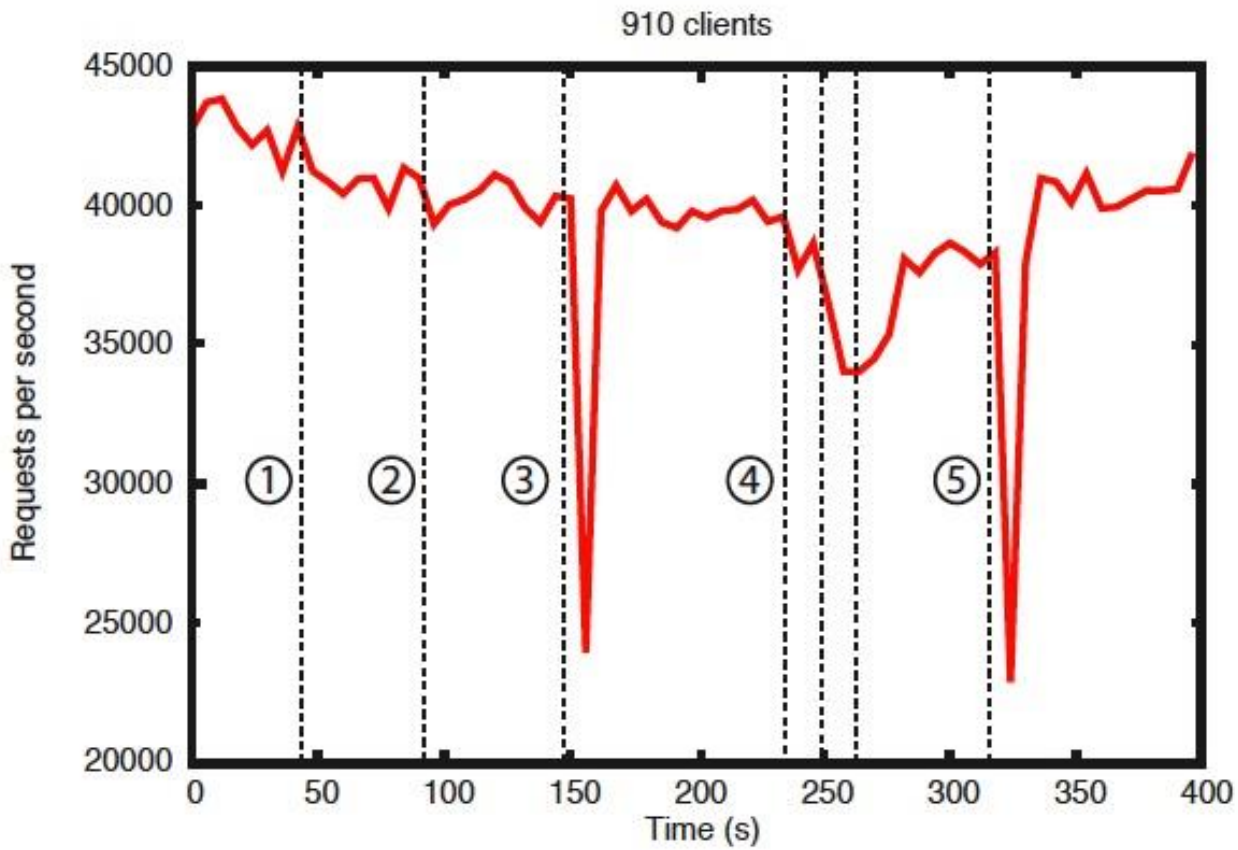

1. Сбой и восстановление follower
2. Сбой и восстановление другого follower
3. Сбой leader
4. Сбой и восстановление двух follower
5. Сбой нового leader

http://zookeeper.apache.org/doc/r3.3.5/zookeeperOver.html

ИНСТИТУТ ЦИФРОВОГО ОБРАЗОВАНИЯ МГПУ

Надстройка. Curator

Curator Framework высокоуровневое API, которое упрощает работу с Zookeeper’ом

Некоторые особенности:

- Автоматическое восстановление соединения при возникновении ошибок
- Простое и понятное API для работы с методами и событиями ZK
- Готовые реализации выбора лидера, распределённой блокировки, распределённых очередей и др.

http://curator.apache.org/curator-framework/

Источники

ZooKeeper by Flavio Junqueira and Benjamin Reed (book)

Zookeeper (github source code)

ZooKeeper: A Distributed Coordination Service for Distributed Applications (doc)

ZooKeeper Programmer's Guide (doc)

ZooKeeper Recipes and Solutions (doc)

В чем польза ZooKeeper для админов и разработчиков. Семинар в Яндексе (blog)